Titanic — eksploracyjna analiza danych (EDA)

Cel projektu

Celem tego notebooka jest przeprowadzenie eksploracyjnej analizy danych pasażerów Titanica (Exploratory Data Analysis, EDA). Analiza koncentruje się na jakości i kompletności danych oraz na sprawdzeniu, jak przeżywalność pasażerów wiąże się z wybranymi cechami, takimi jak klasa podróży, płeć, wiek, cena biletu i port wejścia na pokład.

Pracę wykonano w Pythonie z wykorzystaniem biblioteki **Pandas** oraz wykresów tworzonych za pomocą **Matplotlib** i **Seaborn.**

Pytania badawcze

- Jak różnił się odsetek przeżycia między klasami podróży?
- Jak duże były różnice w przeżywalności kobiet i mężczyzn w poszczególnych klasach?
- Jak przeżywalność wyglądała w różnych grupach wiekowych, w tym wśród osób poniżej 18 lat?
- Jak rozkładały się wiek i ceny biletów pomiędzy klasami oraz jakie zależności można zauważyć na wykresach?
- Jakie ograniczenia analizy wynikają z brakujących danych i wartości odstających?

Zakres i metoda

Analiza obejmuje przegląd struktury zbioru, typów danych, duplikatów i brakujących wartości; statystyki opisowe; porównania według klasy, płci, wieku i portu zaokrętowania; a także histogramy, wykresy słupkowe, wykresy rozrzutu, macierze korelacji i wykresy pudełkowe.

W zbiorze znajdował się jeden całkowicie pusty wiersz — został usunięty. Jedyną brakującą cenę biletu uzupełniono średnią ceną biletu w III klasie. Pozostałe braki nie zostały ogólnie uzupełnione, dlatego liczba obserwacji może się różnić pomiędzy analizami poszczególnych zmiennych.

Ważne ograniczenia

Jest to analiza eksploracyjna, a nie model predykcyjny ani badanie przyczynowości. Zaobserwowane zależności opisują dostępny zbiór danych i same w sobie nie dowodzą, że dana cecha była przyczyną przeżycia. Wyniki należy interpretować z uwzględnieniem niekompletnych zapisów, zwłaszcza dla wieku, kabiny, łodzi ratunkowej, numeru ciała i miejsca docelowego.

> **Plik wejściowy:** notebook oczekuje pliku `26__titanic.csv` w katalogu 'data'. Przed uruchomieniem sprawdź, czy plik CSV znajduje się we właściwej lokalizacji.

0. O Danych

Dane o pasażerach Titanica

Zbiór danych zawiera informacje o pasażerach RMS Titanic, który zatonął 15 kwietnia 1912 roku po zderzeniu z górą lodową. Dane obejmują takie atrybuty jak klasa podróży, wiek, płeć, liczba rodzeństwa/małżonków na pokładzie, liczba rodziców/dzieci na pokładzie, cena biletu oraz miejsce zaokrętowania.

Zbiór zawiera także informację o tym, czy pasażer przeżył katastrofę.

Titanic przewoził ponad 2,200 osób, z czego ponad 1,500 zginęło, co czyni tę katastrofę jedną z najbardziej tragicznych w historii morskiej.

Kolumny:

- **pclass** - Klasa biletu
- **survived** - Czy pasażer przeżył katastrofę
- **name** - Imię i nazwisko pasażera
- **sex** - Płeć pasażera
- **age** - Wiek pasażera
- **sibsp** - Liczba rodzeństwa/małżonków na pokładzie
- **parch** - Liczba rodziców/dzieci na pokładzie
- **ticket** - Numer biletu
- **fare** - Cena biletu
- **cabin** - Numer kabiny
- **embarked** - Port, w którym pasażer wszedł na pokład (C = Cherbourg, Q = Queenstown, S = Southampton)
- **boat** - Numer łodzi ratunkowej
- **body** - Numer ciała (jeśli pasażer nie przeżył i ciało zostało odnalezione)
- **home.dest** - Miejsce docelowe

Wczytanie bibliotek, danych

```
Source file: 26__titanic.csv
Dataset dimensions: 1310 rows × 14 columns
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	emba
0	1.0	1.0	Allen, Miss. Elisabeth Walton	female	29.0000	0.0	0.0	24160	211.3375	B5	
1	1.0	1.0	Allison, Master. Hudson Trevor	male	0.9167	1.0	2.0	113781	151.5500	C22 C26	
2	1.0	0.0	Allison, Miss. Helen Loraine	female	2.0000	1.0	2.0	113781	151.5500	C22 C26	
3	1.0	0.0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1.0	2.0	113781	151.5500	C22 C26	
4	1.0	0.0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1.0	2.0	113781	151.5500	C22 C26	
...	...	...	...	...	...	...	...	...	...	...	
1305	3.0	0.0	Zabour, Miss. Thamine	female	NaN	1.0	0.0	2665	14.4542	NaN	
1306	3.0	0.0	Zakarian, Mr. Mapriededer	male	26.5000	0.0	0.0	2656	7.2250	NaN	
1307	3.0	0.0	Zakarian, Mr. Ortin	male	27.0000	0.0	0.0	2670	7.2250	NaN	
1308	3.0	0.0	Zimmerman, Mr. Leo	male	29.0000	0.0	0.0	315082	7.8750	NaN	
1309	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	

1310 rows × 14 columns

1. Przegląd danych

- Informacje o zbiorze / danych

- **pclass** - Klasa biletu
- **survived** - Czy pasażer przeżył katastrofę
- **name** - Imię i nazwisko pasażera
- **sex** - Płeć pasażera
- **age** - Wiek pasażera

- **sibsp** - Liczba rodzeństwa/małżonków na pokładzie
- **parch** - Liczba rodziców/dzieci na pokładzie
- **ticket** - Numer biletu
- **fare** - Cena biletu
- **cabin** - Numer kabiny
- **embarked** - Port, w którym pasażer wszedł na pokład (C = Cherbourg, Q = Queenstown, S = Southampton)
- **boat** - Numer łodzi ratunkowej
- **body** - Numer ciała (jeśli pasażer nie przeżył i ciało zostało odnalezione)
- **home.dest** - Miejsce docelowe

- Próbki

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
848	3.0	0.0	Hansen, Mr. Claus Peter	male	41.0	2.0	0.0	350026	14.1083	NaN	S
1011	3.0	0.0	McNamee, Mrs. Neal (Eileen O'Leary)	female	19.0	1.0	0.0	376566	16.1000	NaN	S
1219	3.0	0.0	Spector, Mr. Woolf	male	NaN	0.0	0.0	A.5. 3236	8.0500	NaN	S
832	3.0	0.0	Goodwin, Mrs. Frederick (Augusta Tyler)	female	43.0	1.0	6.0	CA 2144	46.9000	NaN	S
1036	3.0	1.0	Moubarek, Mrs. George (Omine "Amenia" Alexander)	female	NaN	0.0	2.0	2661	15.2458	NaN	C
473	2.0	0.0	Knight, Mr. Robert J	male	NaN	0.0	0.0	239855	0.0000	NaN	S
683	3.0	0.0	Bourke, Mr. John	male	40.0	1.0	1.0	364849	15.5000	NaN	Q
925	3.0	0.0	Kelly, Mr. James	male	44.0	0.0	0.0	363592	8.0500	NaN	S
113	1.0	1.0	Fortune, Miss. Mabel Helen	female	23.0	3.0	2.0	19950	263.0000	C23 C25 C27	S
809	3.0	0.0	Ford, Mr. Edward Watson	male	18.0	2.0	2.0	W./C. 6608	34.3750	NaN	S

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1310 entries, 0 to 1309
Data columns (total 14 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   pclass     1309 non-null   float64
 1   survived   1309 non-null   float64
 2   name       1309 non-null   object
 3   sex        1309 non-null   object
 4   age        1046 non-null   float64
 5   sibsp      1309 non-null   float64
 6   parch      1309 non-null   float64
 7   ticket     1309 non-null   object
 8   fare       1308 non-null   float64
 9   cabin      295 non-null    object
 10  embarked   1307 non-null   object
 11  boat       486 non-null    object
 12  body       121 non-null    float64
 13  home.dest  745 non-null    object
dtypes: float64(7), object(7)
memory usage: 143.4+ KB
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	ho
0	1.0	323	323	323	284	323	323	323	323	256	321	201	35	
1	2.0	277	277	277	261	277	277	277	277	23	277	112	31	
2	3.0	709	709	709	501	709	709	709	708	16	709	173	55	

Niepełne dane

- Na tytaniku było ponad 2200 osób
- zmarło ponad 1500
- Dane posiadane o 1310 pasażerach więc dane są niepełne
  - W celu analizy założy się, że brakujące informacje nie wpłyną na wyniki

```
pclass          3
survived        2
name         1307
sex             2
age            98
sibsp           7
parch           8
ticket        929
fare          281
cabin         186
embarked        3
boat           27
body          121
home.dest     369
dtype: int64

48.51851851851852
```

- liczba klass: 3
- liczba łódek do ratowania 27 na 1310 pasażerów`

```
0
```

```
pclass       True
survived     True
name         True
sex          True
age          True
sibsp        True
parch        True
ticket       True
fare         True
cabin        True
embarked     True
boat         True
body         True
home.dest    True
dtype: bool
```

```
pclass          1
survived        1
name            1
sex             1
age           264
sibsp           1
parch           1
ticket          1
fare            2
cabin        1015
embarked        3
boat          824
body         1189
home.dest     565
dtype: int64
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	bod
1309	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Nal

2. Brakujące Wartości

- Pusty zbiór

- brak zduplikowanych danych
- wiersz 1309 - jest pustym zbiorem - zostanie usunięty bo nie wnosi żadnych informacji w zbiorze

```
pclass       False
survived     False
name         False
sex          False
age           True
sibsp        False
parch        False
ticket       False
fare          True
cabin         True
embarked      True
boat          True
body          True
home.dest     True
dtype: bool
```

```
pclass          0
survived        0
name            0
sex             0
age           263
sibsp           0
parch           0
ticket          0
fare            1
cabin        1014
embarked        2
boat          823
body         1188
home.dest     564
dtype: int64
```

```
pclass          3
survived        2
name         1307
sex             2
age            98
sibsp           7
parch           8
ticket        929
fare          281
cabin         186
embarked        3
boat           27
body          121
home.dest     369
dtype: int64
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	bc
1225	3.0	0.0	Storey, Mr. Thomas	male	60.5	0.0	0.0	3701	NaN	NaN	S	NaN	26

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
600	3.0	0.0	Abbing, Mr. Anthony	male	42.0	0.0	0.0	C.A. 5547	7.5500	NaN	S
601	3.0	0.0	Abbott, Master. Eugene Joseph	male	13.0	0.0	2.0	C.A. 2673	20.2500	NaN	S
602	3.0	0.0	Abbott, Mr. Rossmore Edward	male	16.0	1.0	1.0	C.A. 2673	20.2500	NaN	S
603	3.0	1.0	Abbott, Mrs. Stanton (Rosa Hunt)	female	35.0	1.0	1.0	C.A. 2673	20.2500	NaN	S
604	3.0	1.0	Abelseth, Miss. Karen Marie	female	16.0	0.0	0.0	348125	7.6500	NaN	S
...	...	...	...	...	...	...	...	...	...	...	...
1304	3.0	0.0	Zabour, Miss. Hileni	female	14.5	1.0	0.0	2665	14.4542	NaN	C
1305	3.0	0.0	Zabour, Miss. Thamine	female	NaN	1.0	0.0	2665	14.4542	NaN	C
1306	3.0	0.0	Zakarian, Mr. Mapriededer	male	26.5	0.0	0.0	2656	7.2250	NaN	C
1307	3.0	0.0	Zakarian, Mr. Ortin	male	27.0	0.0	0.0	2670	7.2250	NaN	C
1308	3.0	0.0	Zimmerman, Mr. Leo	male	29.0	0.0	0.0	315082	7.8750	NaN	S

709 rows × 14 columns

```
13.302888700564973
```

```
pclass                      3.0
survived                    0.0
name         Storey, Mr. Thomas
sex                        male
age                        60.5
sibsp                       0.0
parch                       0.0
ticket                     3701
fare                  13.302889
cabin                       NaN
embarked                      S
boat                        NaN
body                      261.0
home.dest                   NaN
Name: 1225, dtype: object
```

```
pclass          0
survived        0
name            0
sex             0
age           263
sibsp           0
parch           0
ticket          0
fare            0
cabin        1014
embarked        2
boat          823
body         1188
home.dest     564
dtype: int64
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1309 entries, 0 to 1308
Data columns (total 14 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   pclass     1309 non-null   float64
 1   survived   1309 non-null   float64
 2   name       1309 non-null   object
 3   sex        1309 non-null   object
 4   age        1046 non-null   float64
 5   sibsp      1309 non-null   float64
 6   parch      1309 non-null   float64
 7   ticket     1309 non-null   object
 8   fare       1309 non-null   float64
 9   cabin      295 non-null    object
 10  embarked   1307 non-null   object
 11  boat       486 non-null    object
 12  body       121 non-null    float64
 13  home.dest  745 non-null    object
dtypes: float64(7), object(7)
memory usage: 143.3+ KB
```

- Brak ceny biletu

- podsumawanie pustych danych już jest bardziej przejrzyste

- Widać brak ceny u jednego pasażera. Należał do klasy 3. By uniknąć większego błędu pusta wartość została uzupełniona o średnią wartość biletu z klasy 3.

- Podsumowanie

Pozostałe braki danych występują w zmiennych:

- **age** - Wiek pasażera
- **cabin** - Numer kabiny
- **embarked** - Port, w którym pasażer wszedł na pokład (C = Cherbourg, Q = Queenstown, S = Southampton)
- **boat** - Numer łodzi ratunkowej
- **body** - Numer ciała (jeśli pasażer nie przeżył i ciało zostało odnalezione)
- **home.dest** - Miejsce docelowe

Braki informacji w tych danych albo są ważne / konieczne albo nie powinny zmienić końcowych wniosków

3. Analiza poszczególnych zmiennych

	pclass	survived	age	sibsp	parch	fare	body
count	1309.000000	1309.000000	1046.000000	1309.000000	1309.000000	1309.000000	121.000000
mean	2.294882	0.381971	29.881135	0.498854	0.385027	33.280206	160.809917
std	0.837836	0.486055	14.413500	1.041658	0.865560	51.741830	97.696922
min	1.000000	0.000000	0.166700	0.000000	0.000000	0.000000	1.000000
25%	2.000000	0.000000	21.000000	0.000000	0.000000	7.895800	72.000000
50%	3.000000	0.000000	28.000000	0.000000	0.000000	14.454200	155.000000
75%	3.000000	1.000000	39.000000	1.000000	0.000000	31.275000	256.000000
max	3.000000	1.000000	80.000000	8.000000	9.000000	512.329200	328.000000

```
pclass
['survived', 'name', 'sex', 'age', 'sibsp', 'parch', 'ticket', 'fare', 'cabin', 'embarke
d', 'boat', 'body', 'home.dest']
```

	pclass							survived	
		count	mean	std	min	25%	50%	75%	max
0	1.0	323.0	0.619195	0.486338	0.0	0.0	1.0	1.0	1.0
1	2.0	277.0	0.429603	0.495915	0.0	0.0	0.0	1.0	1.0
2	3.0	709.0	0.255289	0.436331	0.0	0.0	0.0	1.0	1.0

	pclass	name			
		count	unique	top	freq
0	1.0	323	323	Allen, Miss. Elisabeth Walton	1
1	2.0	277	277	Abelson, Mr. Samuel	1
2	3.0	709	707	Connolly, Miss. Kate	2

	pclass	sex			
		count	unique	top	freq
0	1.0	323	2	male	179
1	2.0	277	2	male	171
2	3.0	709	2	male	493

	pclass	age						
		count	mean	std	min	25%	50%	75%	max
0	1.0	284.0	39.159918	14.548059	0.9167	28.0	39.0	50.0	80.0
1	2.0	261.0	29.506705	13.638628	0.6667	22.0	29.0	36.0	70.0
2	3.0	501.0	24.816367	11.958202	0.1667	18.0	24.0	32.0	74.0

	pclass	sibsp						
		count	mean	std	min	25%	50%	75%	max
0	1.0	323.0	0.436533	0.609064	0.0	0.0	0.0	1.0	3.0
1	2.0	277.0	0.393502	0.590100	0.0	0.0	0.0	1.0	3.0
2	3.0	709.0	0.568406	1.299681	0.0	0.0	0.0	1.0	8.0

	pclass	parch						
		count	mean	std	min	25%	50%	75%	max
0	1.0	323.0	0.365325	0.715602	0.0	0.0	0.0	0.5	4.0
1	2.0	277.0	0.368231	0.692717	0.0	0.0	0.0	1.0	3.0
2	3.0	709.0	0.400564	0.981639	0.0	0.0	0.0	0.0	9.0

	pclass	ticket			
		count	unique	top	freq
0	1.0	323	188	PC 17608	7
1	2.0	277	192	S.O.C. 14879	7
2	3.0	709	549	CA. 2343	11

	pclass								fare
		count	mean	std	min	25%	50%	75%	max
0	1.0	323.0	87.508992	80.447178	0.0	30.6958	60.0000	107.6625	512.3292
1	2.0	277.0	21.179196	13.607122	0.0	13.0000	15.0458	26.0000	73.5000
2	3.0	709.0	13.302889	11.486238	0.0	7.7500	8.0500	15.2458	69.5500

	pclass				cabin
		count	unique	top	freq
0	1.0	256	168	C23 C25 C27	6
1	2.0	23	9	D	4
2	3.0	16	9	G6	5

	pclass			embarked	
		count	unique	top	freq
0	1.0	321	3	S	177
1	2.0	277	3	S	242
2	3.0	709	3	S	495

	pclass				boat
		count	unique	top	freq
0	1.0	201	21	5	27
1	2.0	112	12	14	23
2	3.0	173	18	C	36

	pclass								body
		count	mean	std	min	25%	50%	75%	max
0	1.0	35.0	162.828571	82.652172	16.0	109.5	166.0	233.0	307.0
1	2.0	31.0	167.387097	107.077753	15.0	78.0	155.0	284.5	322.0
2	3.0	55.0	155.818182	102.403720	1.0	67.5	153.0	257.0	328.0

	pclass			home.dest	
		count	unique	top	freq
0	1.0	289	123	New York, NY	55
1	2.0	261	157	London	10
2	3.0	195	110	Wiltshire, England Niagara Falls, NY	8

	pclass									survived	age	...	fare			n
		count	mean	std	min	25%	50%	75%	max	count	...	75%	max	count		
0	1.0	200.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0	181.0	...	120.0000	512.3292	0.0		
1	2.0	119.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0	115.0	...	27.7354	65.0000	0.0		
2	3.0	181.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0	131.0	...	15.7417	56.4958	0.0		

3 rows × 49 columns

- Podsumowanie na daną klasę

- Ilość osób
    1. 323
    2. 277
    3. 709
- Płeć
    1. 179 - Mężczyzna
    2. 171 - Mężczyzna
    3. 493 - Mężczyzna
- Wiek
    1. Klasa 1
        - średnia: 39.16
        - Min: 0.91 (około 11 miesięcy)
        - 50%: 39
        - Max: 80
    2. Klasa 2
        - średnia: 29.5
        - Min: 0.67 (około 8 miesiący)
        - 50%: 29
        - Max: 70
    3. Klasa 3
        - średnia: 24.8
        - Min: 0.16 (około 2 miesiące)
        - 50%: 24
        - Max: 74
- Cena biletu
    1. Klasa 1:
        A. min: 0
        B. przeciętna cena 60
        C. Max: 512.32 - dużo wyższa cena niż przeciętna cena
    2. Klasa 2:
        A. min: 0

    B. przeciętna cena 15
    C. Max: 73.5 - w tej cenie już można było kupić klasę 1 - może czym bliżej dnia wypłynięcia ceny były wyższe, albo zależały od lokalizacji
3. Klasa 3:
    A. min: 0
    B. przeciętna cena 8
    C. Max: 69.55 - dużo wyższa cena niż przeciętna cena

- ilośc kabin na klase

1. 256
2. 23
3. 16

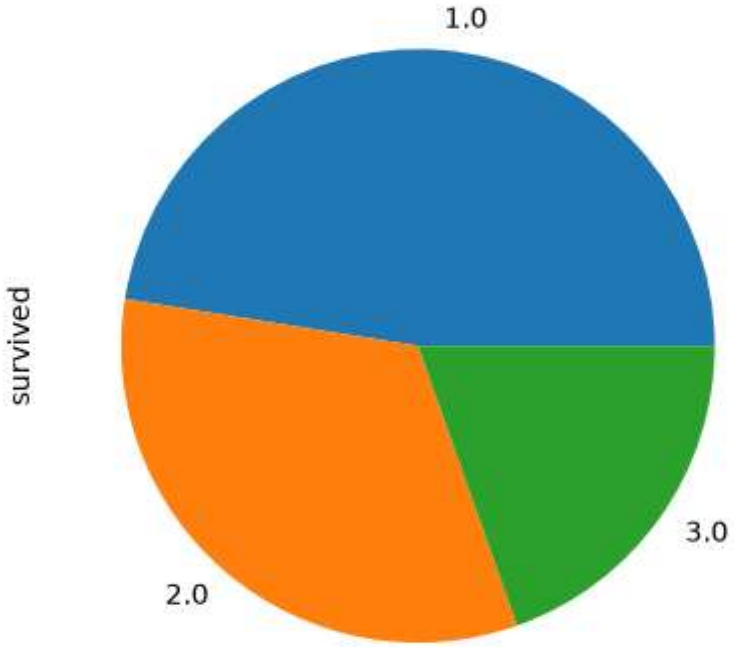
Podsumowanie:

- Widać, że w każdej klasie przeważali nieznacznie mężczyźni.
- W każdej klasie są ceny biletów istnieją skrajności. Np. Za cenę najdroższych biletów w klasie 2 i 3 można było by kupić klasę 1.
- Czym wyższa klasa tym większe różnice w cenie

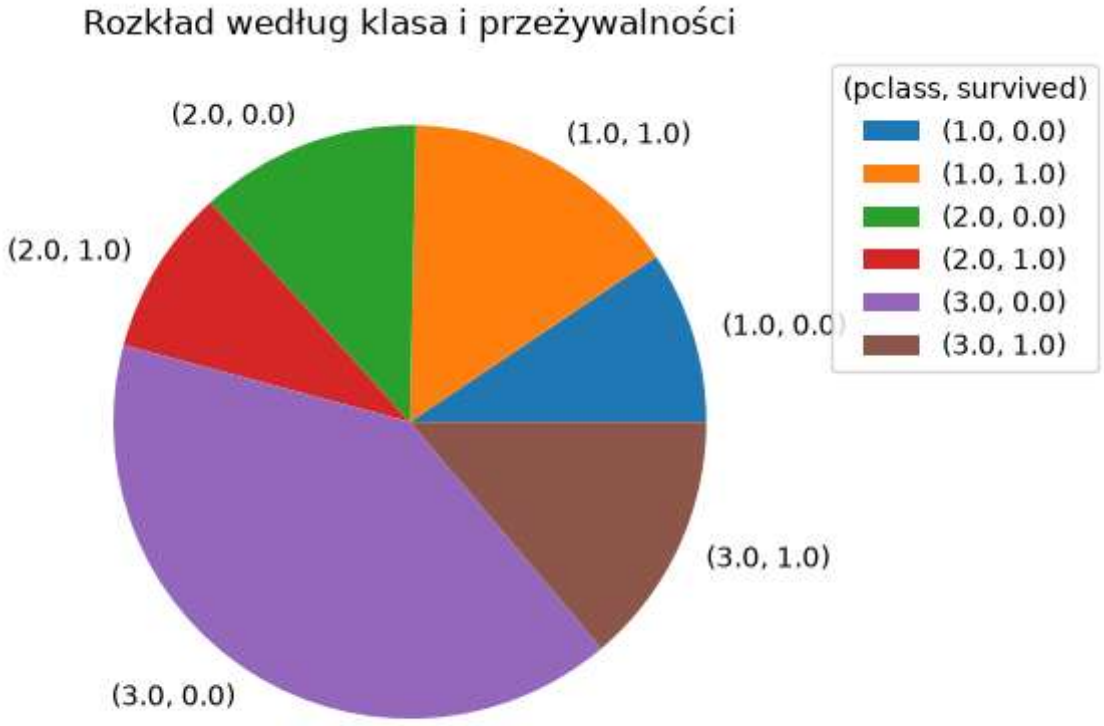
survived	**0.0**	**1.0**
pclass		
1.0	123	200
2.0	158	119
3.0	528	181

```
Średnia Wartość przeżycia w danej klasie [%]:
 pclass
1.0    61.919505
2.0    42.960289
3.0    25.528914
Name: survived, dtype: float64
```

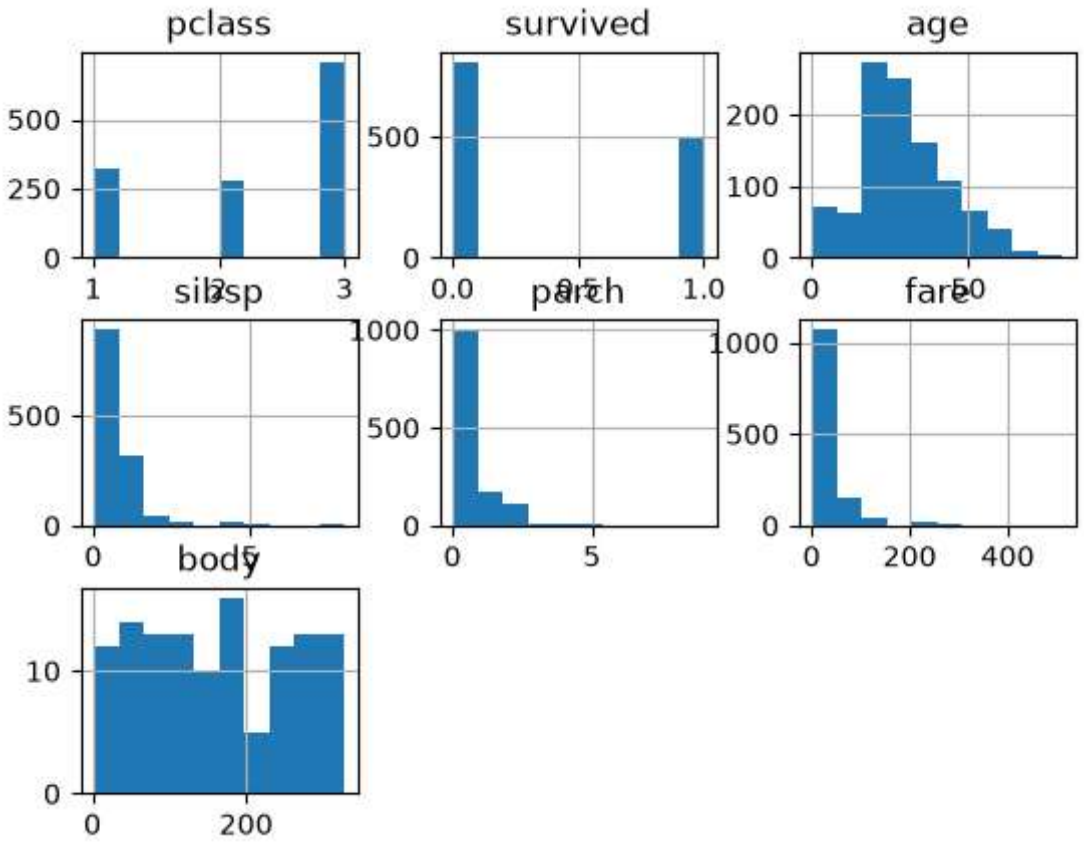
```
<Axes: ylabel='survived'>
```




```
<matplotlib.legend.Legend at 0x1ca7d8ba4d0>
```




```
array([[<Axes: title={'center': 'pclass'}>,
        <Axes: title={'center': 'survived'}>,
        <Axes: title={'center': 'age'}>],
       [<Axes: title={'center': 'sibsp'}>,
        <Axes: title={'center': 'parch'}>,
        <Axes: title={'center': 'fare'}>],
       [<Axes: title={'center': 'body'}>, <Axes: >, <Axes: >]],
      dtype=object)
```



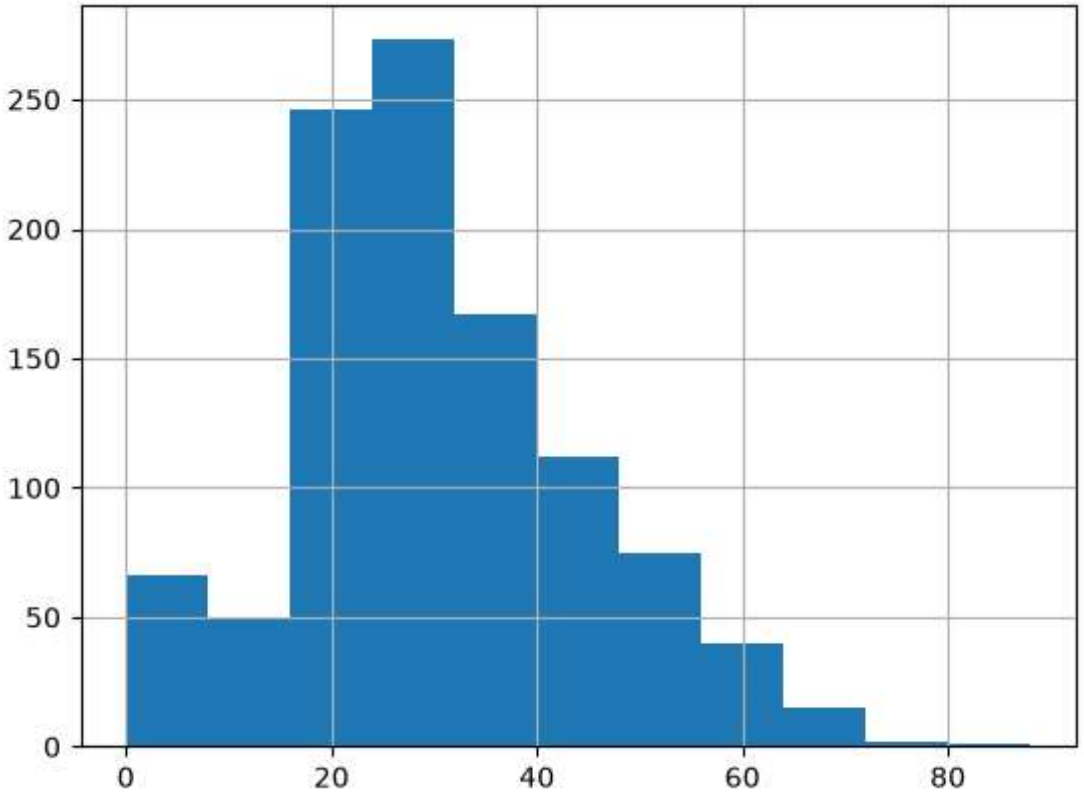
- Analiza przeżycia z rozróżnieniem na klasy

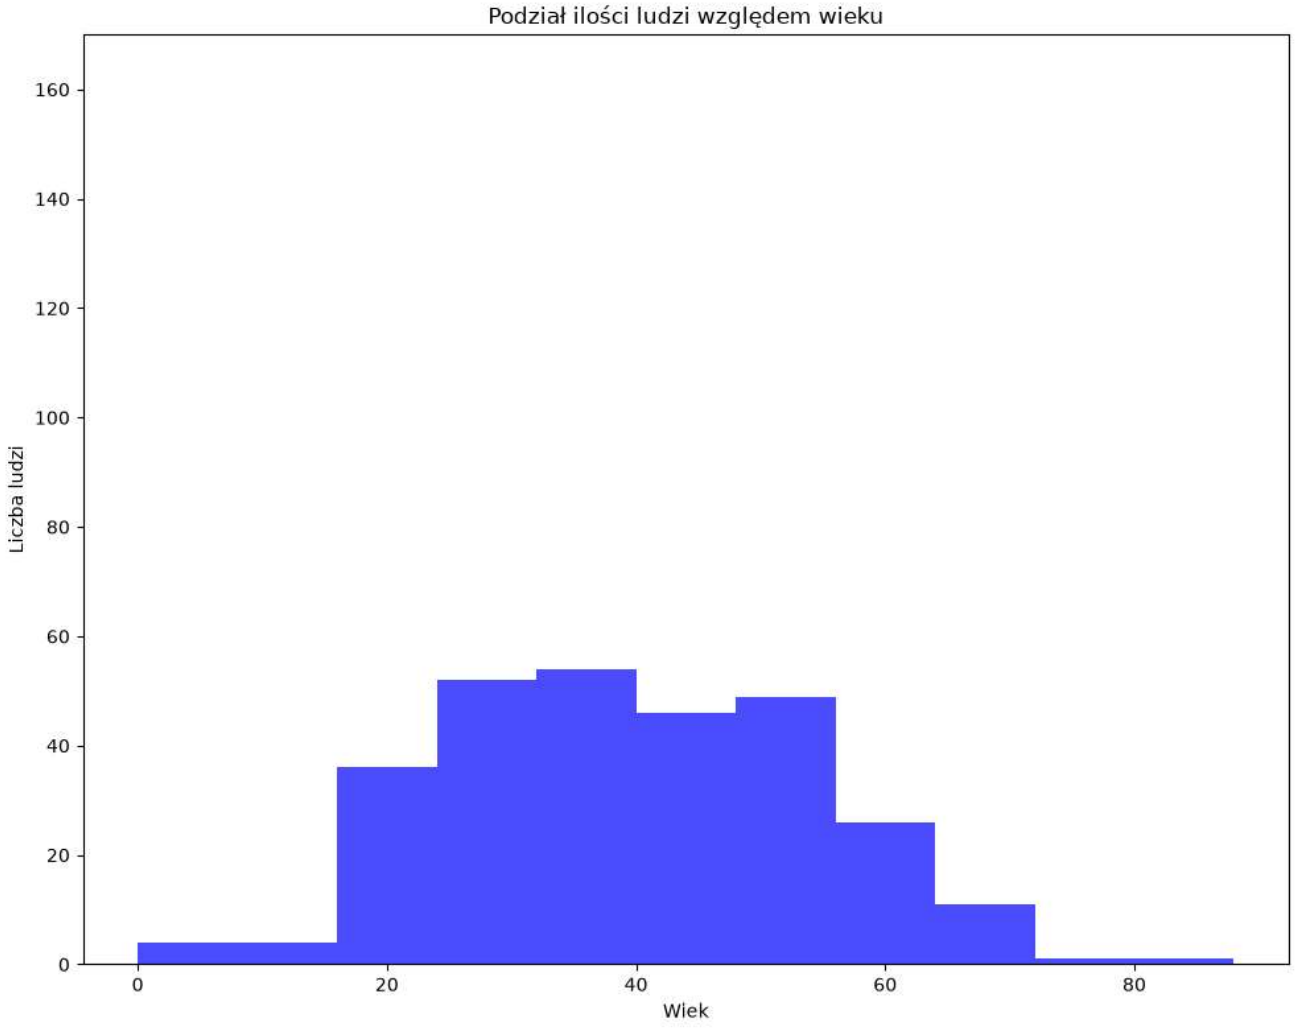
Ilość osób

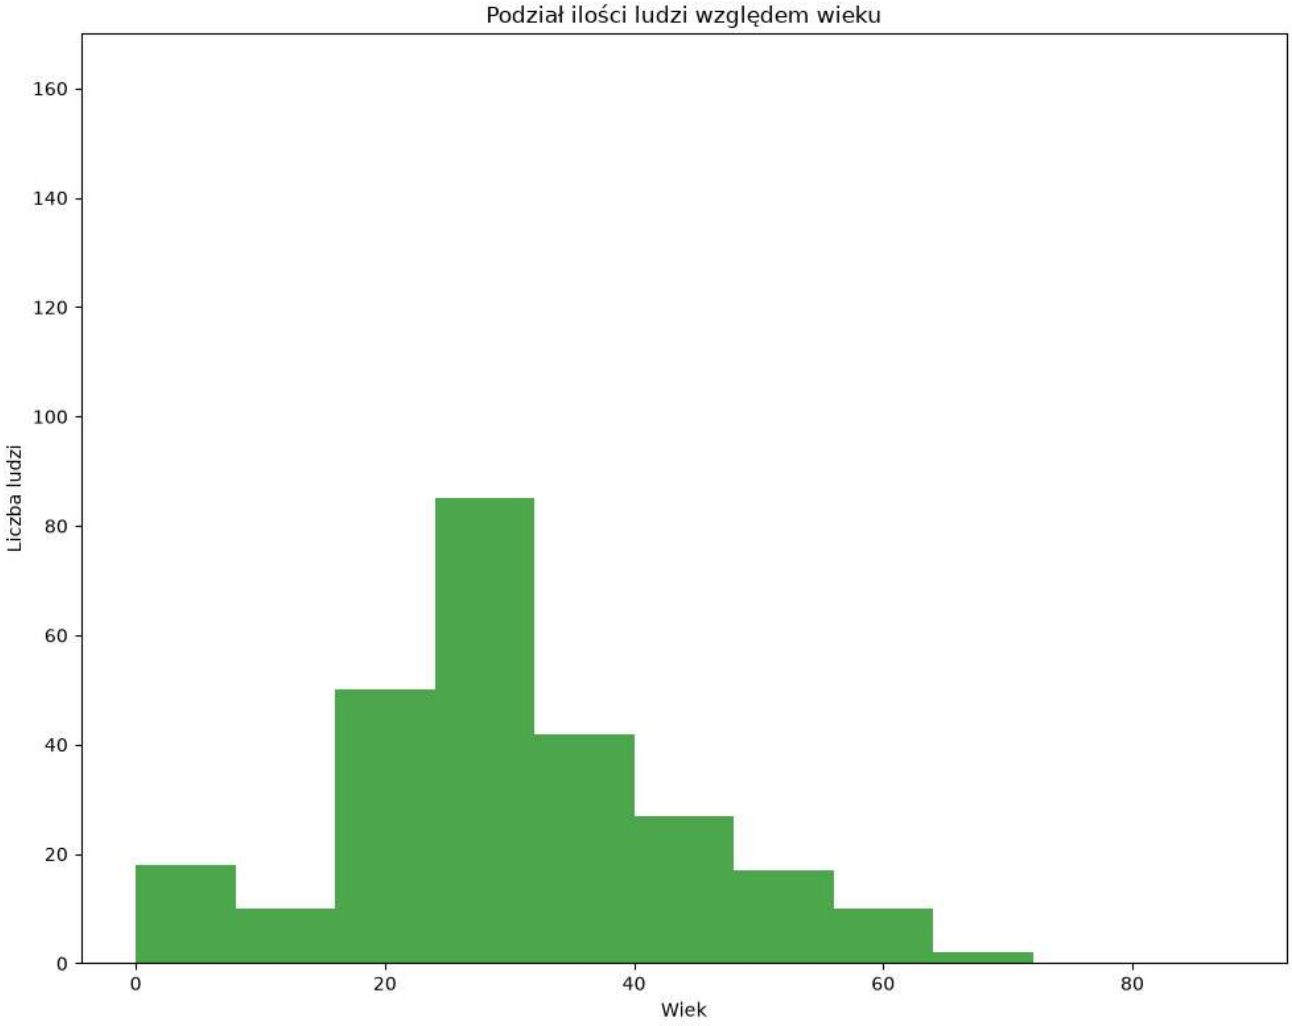
- 323 - przzeżyło: 200 - 61.9 %
- 277 - przzeżyło: 119 - 42.9 %
- 709 - przzeżyło: 181 - 25.5 %

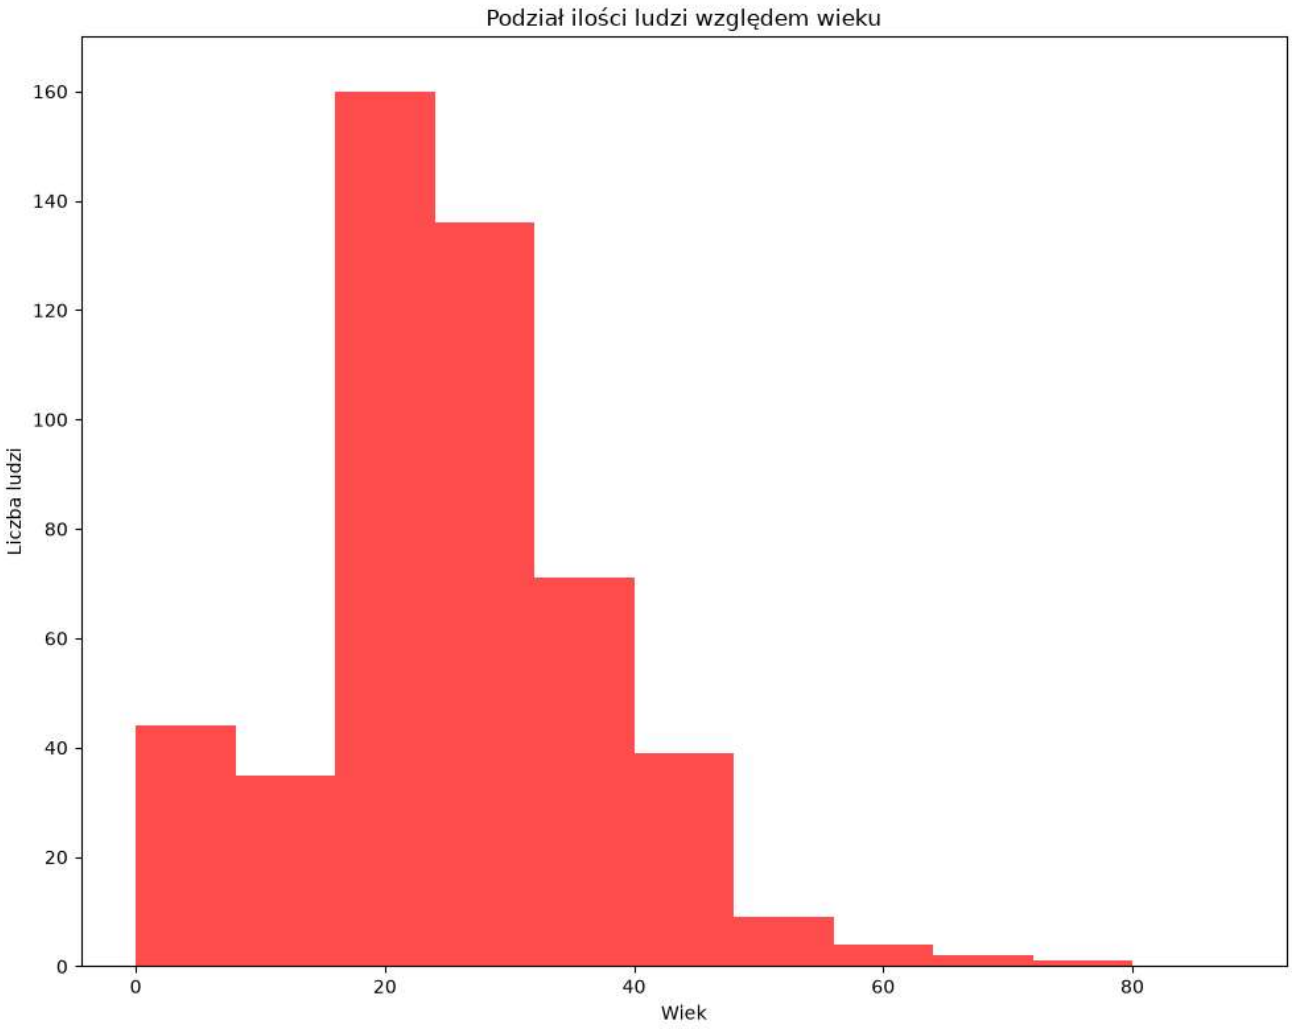
Na wykresach widoczne jest, że wraz z wyższą klasą szanse na przeżycie były znacznie wyższe. Ponad 2 krotnie w porównianiu klasy 1 i 3.

<Axes: >


250
200
150
100
50
0
0
20
40
60
80


Podział ilości ludzi względem wieku
Liczba ludzi
160
140
120
100
80
60
40
20
0
0
20
40
60
80
Wiek


Podział ilości ludzi względem wieku
Liczba ludzi
Wiek
0
20
40
60
80
0
20
40
60
80
100
120
140
160



- Wiek a Klasa

W Klasie 1 najczęściej podróżowały osoby w wieku 20-50 lat.

W Klasie 2 najczęściej podróżowały osoby w wieku 20-50 lat lecz widać prawie 2 krotnie więcej osób w innych ramach w wieku około 30 lat.

W Klasie 3 najczęściej podróżowały osoby w wieku 0-50 lat lecz widać bardzo dużo osób przeważających w wieku 16-32 lata oraz największy udział dzieci, może to świadczyć o tym, że częściej całe młode rodziny udały się w rejs.

4. Transformacja - Analiza danych ludzi z łodzi

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	hon

```
pclass         0
survived       0
name           0
sex            0
age           73
sibsp          0
parch          0
ticket         0
fare           0
cabin        307
embarked       2
boat          23
body         500
home.dest    153
dtype: int64
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embark
13	1.0	1.0	Barber, Miss. Ellen "Nellie"	female	26.0	0.0	0.0	19877	78.8500	NaN	
6	1.0	1.0	Andrews, Miss. Kornelia Theodosia	female	63.0	1.0	0.0	13502	77.9583	D7	
1290	3.0	1.0	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1.0	0.0	363272	7.0000	NaN	
83	1.0	1.0	Crosby, Mrs. Edward Gifford (Catherine Elizabe...	female	64.0	1.0	1.0	112901	26.5500	B26	
207	1.0	1.0	Minahan, Miss. Daisy E	female	33.0	1.0	0.0	19928	90.0000	C78	
50	1.0	1.0	Cardeza, Mrs. James Warburton Martinez (Charlo...	female	58.0	0.0	1.0	PC 17755	512.3292	B51 B53 B55	
780	3.0	1.0	Drapkin, Miss. Jennie	female	23.0	0.0	0.0	SOTON/OQ 392083	8.0500	NaN	
899	3.0	1.0	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	0.0	2.0	347742	11.1333	NaN	
131	1.0	1.0	Gibson, Mrs. Leonard (Pauline C Boeson)	female	45.0	0.0	1.0	112378	59.4000	NaN	
1082	3.0	1.0	Olsen, Master. Artur Karl	male	9.0	0.0	1.0	C 17368	3.1708	NaN	

	pclass							survived	
		count	mean	std	min	25%	50%	75%	max
0	1.0	200.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0
1	2.0	119.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0
2	3.0	181.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0

	pclass				name
		count	unique	top	freq
0	1.0	200	200	Allen, Miss. Elisabeth Walton	1
1	2.0	119	119	Abelson, Mrs. Samuel (Hannah Wizosky)	1
2	3.0	181	181	Abbott, Mrs. Stanton (Rosa Hunt)	1

	pclass			sex	
		count	unique	top	freq
0	1.0	200	2	female	139
1	2.0	119	2	female	94
2	3.0	181	2	female	106

	pclass							age	
		count	mean	std	min	25%	50%	75%	max
0	1.0	181.0	36.833794	14.249562	0.9167	26.0	36.0	48.0	80.0
1	2.0	115.0	24.858696	13.959568	0.6667	17.5	25.0	33.0	62.0
2	3.0	131.0	21.545166	11.607635	0.1667	16.0	22.0	29.0	63.0

	pclass							sibsp	
		count	mean	std	min	25%	50%	75%	max
0	1.0	200.0	0.510000	0.641841	0.0	0.0	0.0	1.0	3.0
1	2.0	119.0	0.487395	0.636004	0.0	0.0	0.0	1.0	3.0
2	3.0	181.0	0.392265	0.757001	0.0	0.0	0.0	1.0	4.0

	pclass							parch	
		count	mean	std	min	25%	50%	75%	max
0	1.0	200.0	0.425000	0.739669	0.0	0.0	0.0	1.0	4.0
1	2.0	119.0	0.689076	0.851200	0.0	0.0	0.0	1.0	3.0
2	3.0	181.0	0.392265	0.742178	0.0	0.0	0.0	1.0	5.0

	pclass	ticket			
		count	unique	top	freq
0	1.0	200	122	PC 17608	6
1	2.0	119	84	230136	4
2	3.0	181	141	1601	6

	pclass	fare						
		count	mean	std	min	25%	50%	75%	max
0	1.0	200.0	98.023314	87.476771	0.0	49.50315	76.7292	120.0000	512.3292
1	2.0	119.0	23.008124	11.269535	10.5	13.00000	23.0000	27.7354	65.0000
2	3.0	181.0	12.916919	9.775015	0.0	7.75000	8.0500	15.7417	56.4958

	pclass	cabin			
		count	unique	top	freq
0	1.0	167	116	B96 B98	4
1	2.0	17	7	F4	4
2	3.0	9	6	G6	3

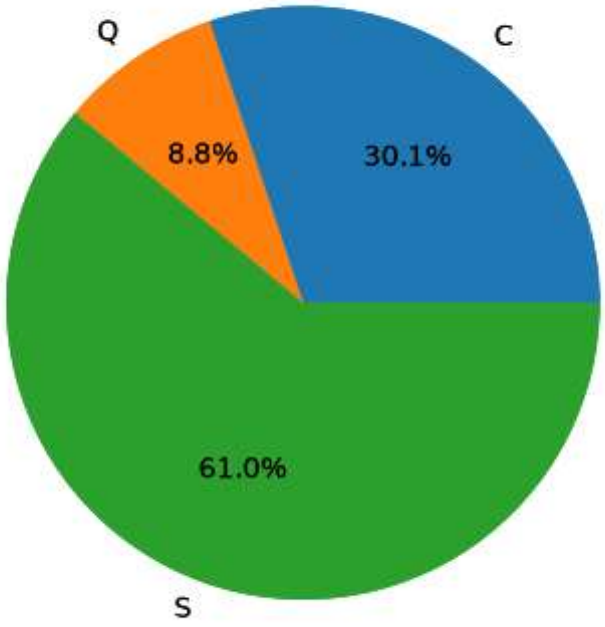
	pclass	embarked			
		count	unique	top	freq
0	1.0	198	3	S	99
1	2.0	119	3	S	101
2	3.0	181	3	S	104

	pclass	boat			
		count	unique	top	freq
0	1.0	199	21	5	27
1	2.0	111	12	14	23
2	3.0	167	18	15	35

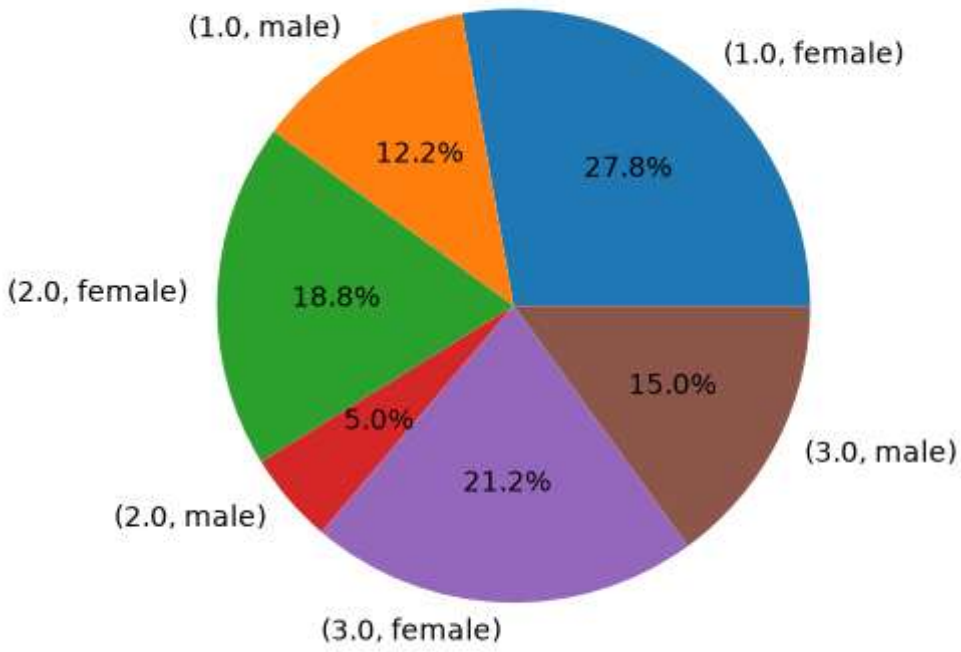
	pclass	body						
		count	mean	std	min	25%	50%	75%	max
0	1.0	0.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	2.0	0.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	3.0	0.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN

	pclass			home.dest	
		count	unique	top	freq
0	1.0	175	79	New York, NY	36
1	2.0	117	76	Cornwall / Akron, OH	8
2	3.0	55	40	Syria New York, NY	4

```
Survived: embarked
C    150
Q     44
S    304
dtype: int64
All: embarked
C    270
Q    123
S    914
dtype: int64
% of survival: embarked
C    55.555556
Q    35.772358
S    33.260394
dtype: float64
```



```
Survived: pclass  sex
1.0     female    139
        male       61
2.0     female     94
        male       25
3.0     female    106
        male       75
dtype: int64
All: pclass  sex
1.0     female    144
        male      179
2.0     female    106
        male      171
3.0     female    216
        male      493
Name: survived, dtype: int64
% of survival: pclass  sex
1.0     female    96.527778
        male      34.078212
2.0     female    88.679245
        male      14.619883
3.0     female    49.074074
        male      15.212982
dtype: float64
<Axes: >
```



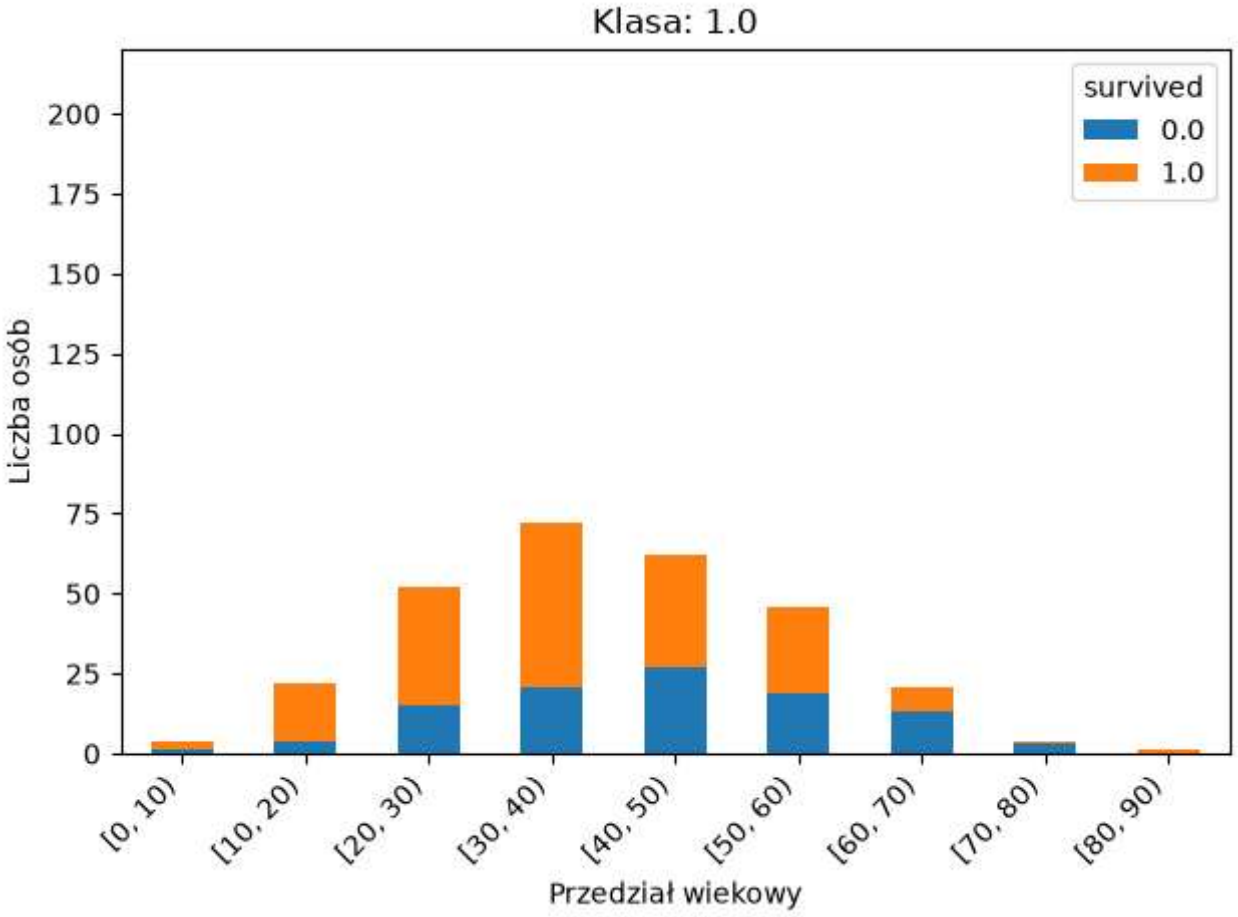
- Podsumowanie Transformowanej Tabeli

- Znacznie więcej Kobiet przeżyło - Kobiety miały pierwszeństwo na wpószczanie na łodzie. Witać po frekwencji przeżycia, że wyższe klasy miały pierwszeństwo wchodzenia na łodzie.
    - % of survival per class:
        - 1.0: female 96.527778, male 34.078212
        - 2.0: female 88.679245, male 14.619883

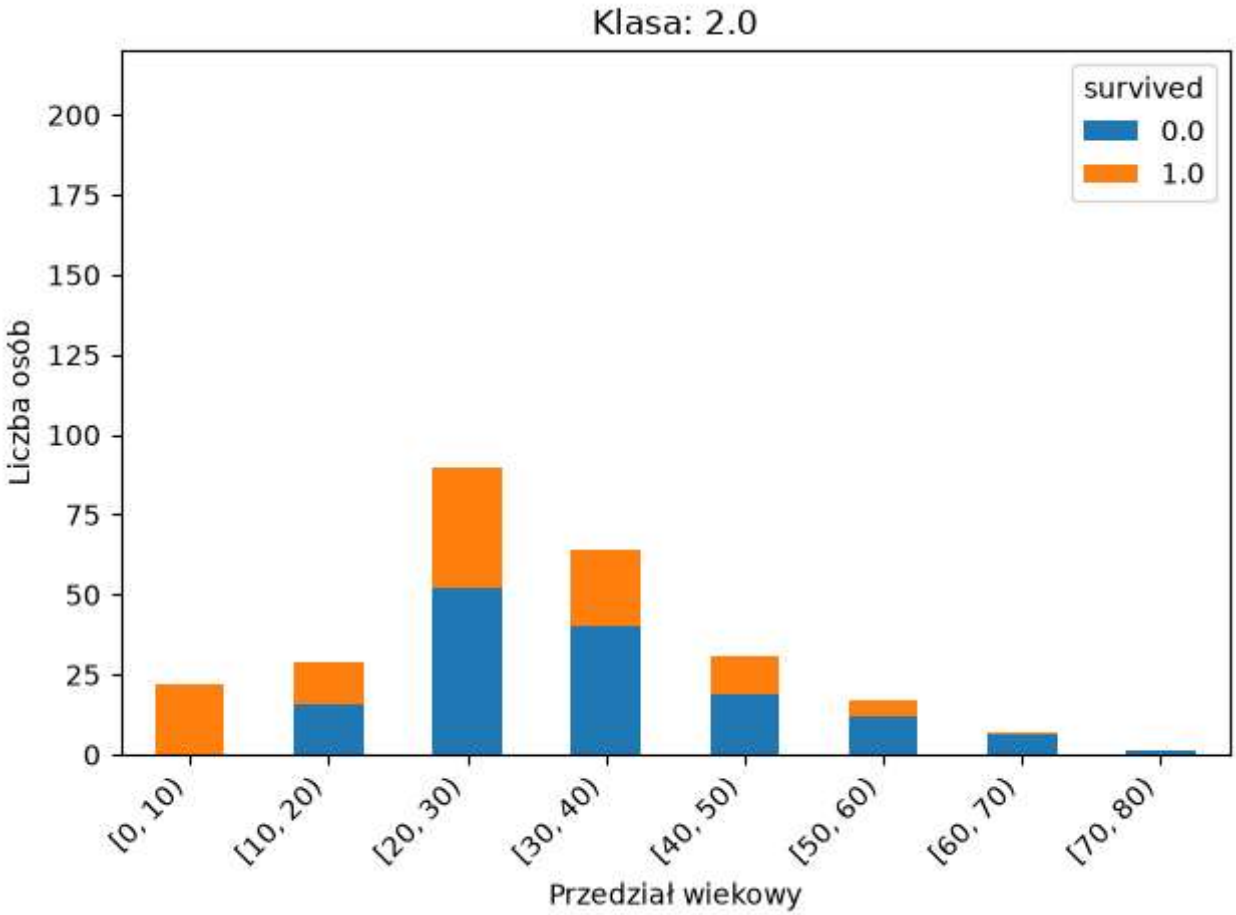
        - 3.0: female 49.074074, male 15.212982
- Widać znaczną różnice w przeżywalności uzależniwszy od miejsca wsiadania na statku względem osób na łodziach lecz uwzględniając ile osób wsiadło w danym miejscu to ten wysoki odsetek raczej wynika z powodu przeważającej ilości osób na pokładzie z portu `Southampton`. Po uwzględnieniu całkowitej ilości pasażerów więcej osób uratowało się z portu `Cherbourg`.
    - C = Cherbourg 30.1%, Q = Queenstown 8.8%, S = Southampton 61%
    - Procent względem ilości osób na statku
        - % of survival:
            - C 55.555556
            - Q 35.772358
            - S 33.260394
- W klasach 2 i 3 więcej przeżyło osób młodych (mniej niż 32 lata) w porównaniu z klasą 1 (w Klasie 1 było więcej osób starszych)

5. Analiza relacji oraz wartości odstających

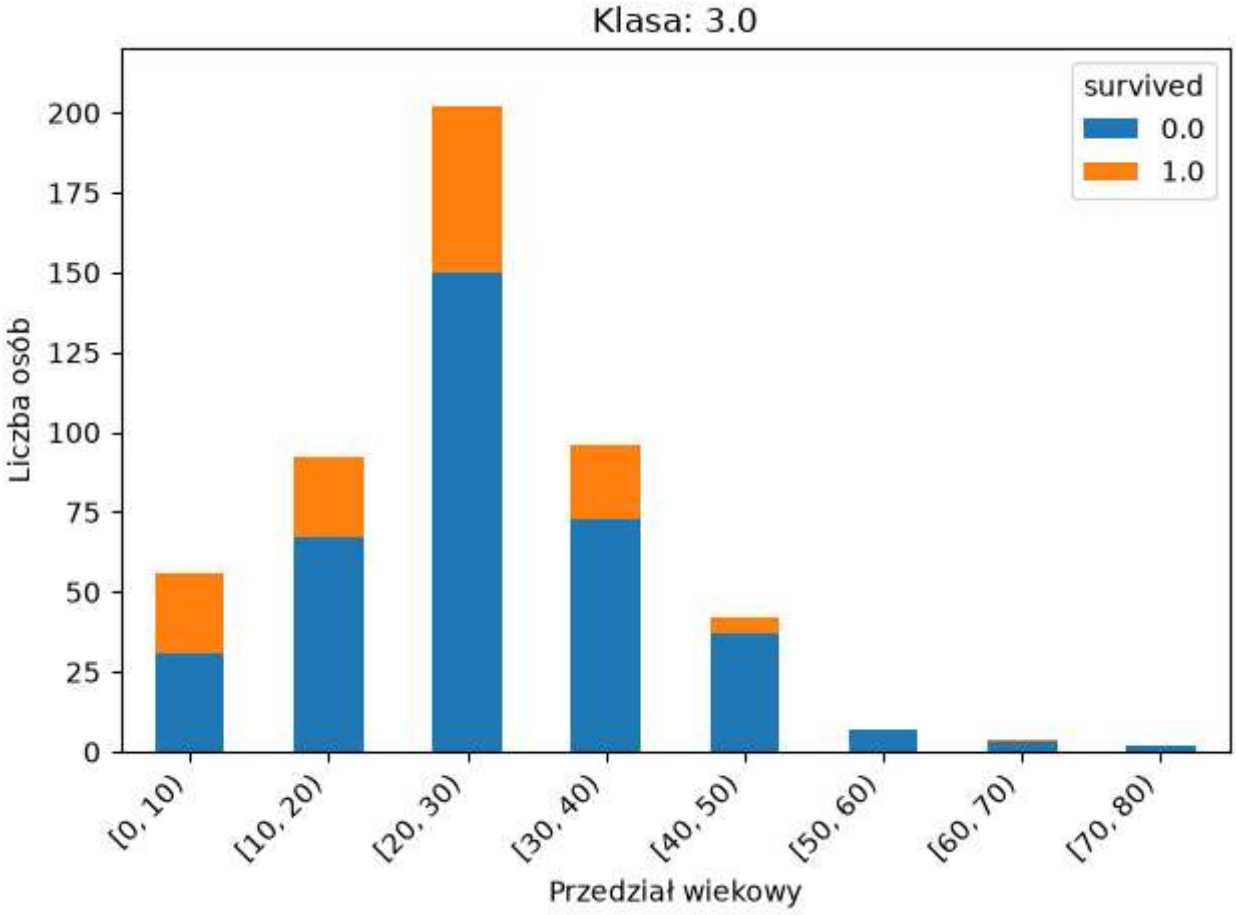
```
<Figure size 1000x800 with 0 Axes>
```



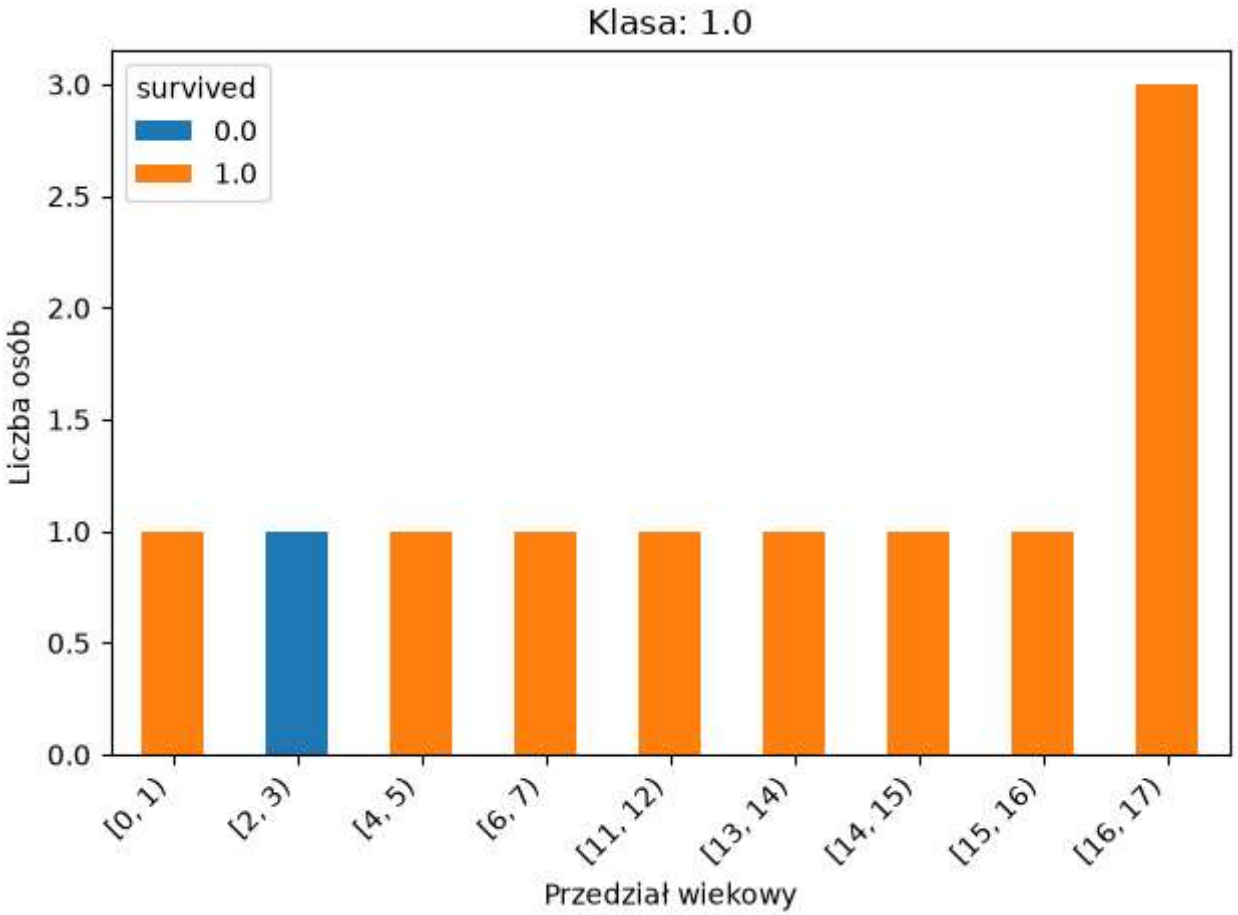

```
<Figure size 1000x800 with 0 Axes>
```



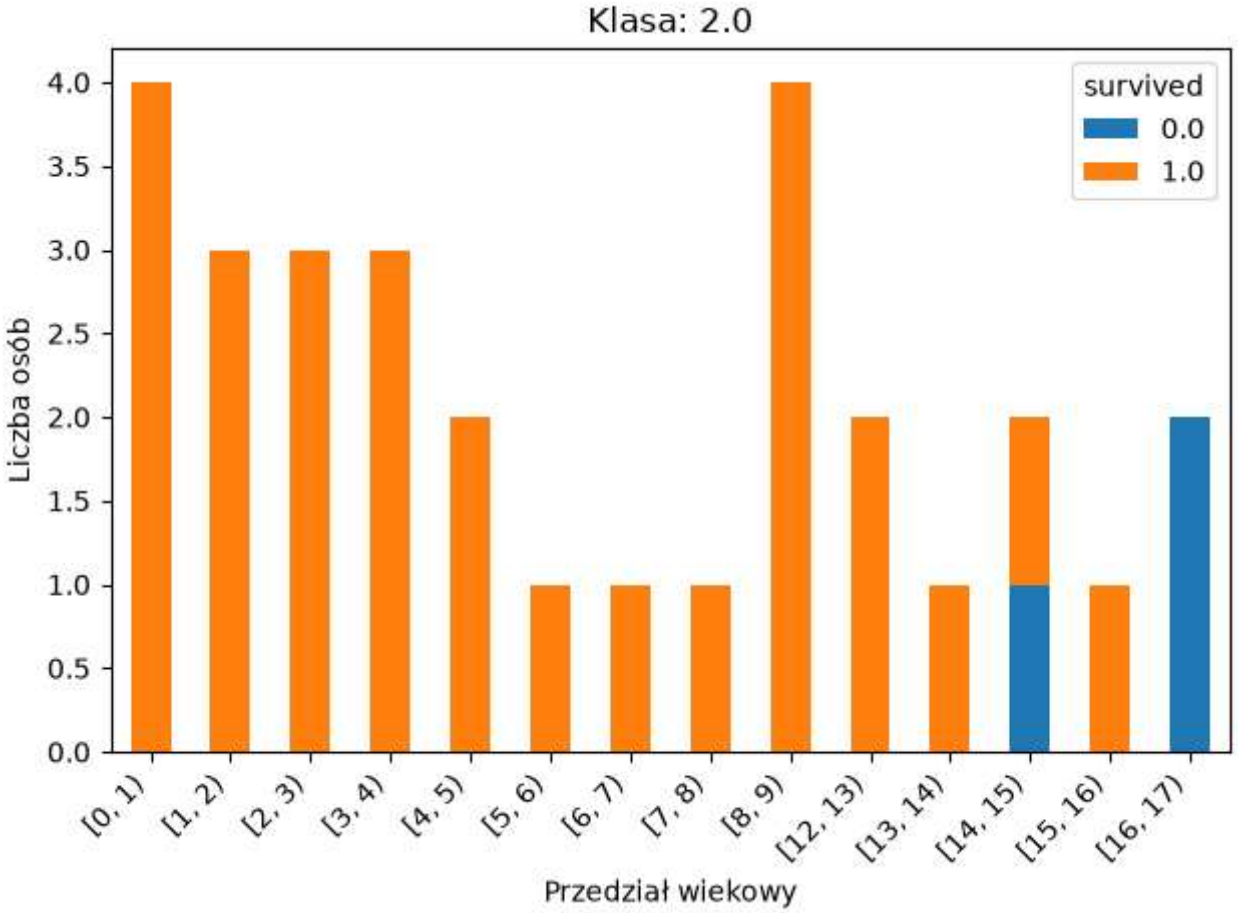
<Figure size 1000x800 with 0 Axes>



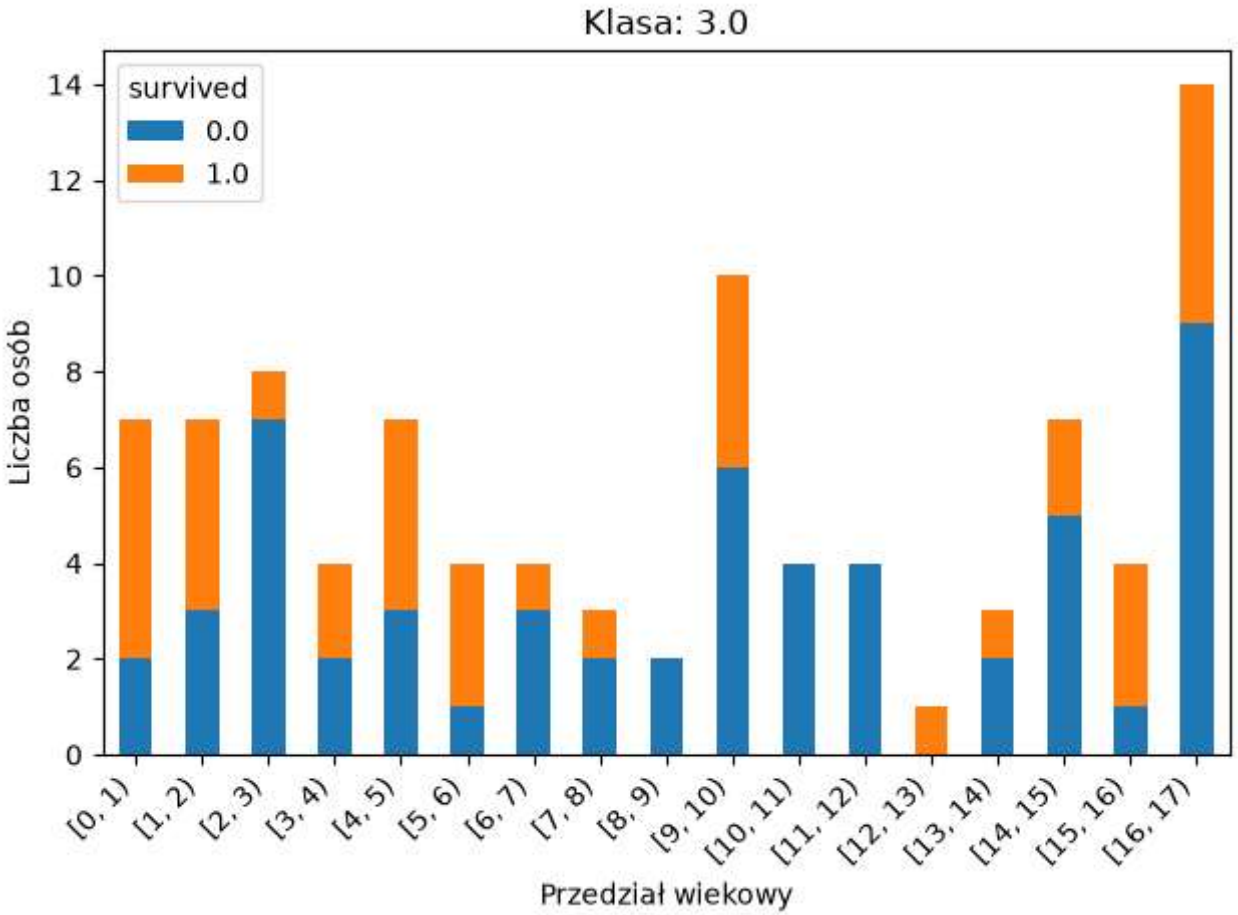
<Figure size 1000x800 with 0 Axes>



<Figure size 1000x800 with 0 Axes>



<Figure size 1000x800 with 0 Axes>




```
pclass
1.0    13
2.0    29
3.0    39
dtype: int64
pclass
1.0     15
2.0     33
3.0    106
dtype: int64
pclass
1.0    86.666667
2.0    87.878788
3.0    36.792453
dtype: float64
```

- Relacje wieku i klasy z przeżyciem

(kolor pomarańczowy oznacza że osoby przeżyły)

- Z pierwszych 3 wykresów gdzie widać cały zbiór osób, że klasa 1 ma największy odsetek przeżycia niezależnie od grupy wiekowej. Widać, że przypisanie do klasy miało wpływ na faworyzowanie w czasie ewakuacji statku.
- Kolejne 3 wykresy skupiają się na podkreśleniu zależności przeżycia / faworyzowania dzieci w wieku 0-17 lat (można było by tu polemizować czy w tamtych czasach 17 latków uważano jeszcze za dzieci). Widać że w klasie 1 i 2 nie było problemu z wpuszczaniem dzieci na szalupy.
- Inaczej to się klaruje w klasie 3 w której było najwięcej dzieci lecz również widać proporcjonalnie śmiertelność była znacznie wyższa. Sugeruje to, że nawet dla małych dzieci był problem znaleźć

miejsce na szalupach.

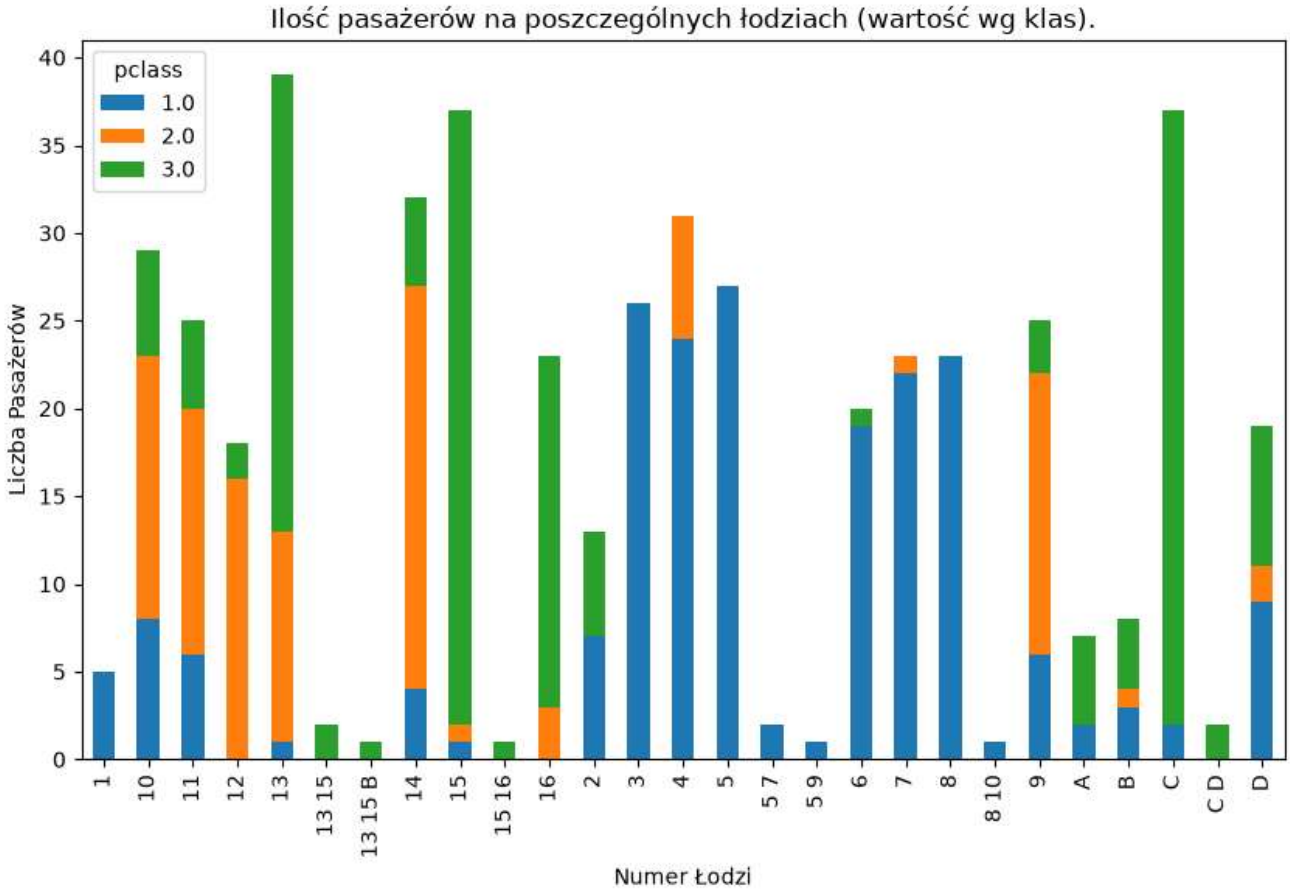
- Klasa: 1.0: **86.666667 %**
- Klasa: 2.0: **87.878788 %**
- Klasa: 3.0: **36.792453 %**

```
pclass  boat
1.0     1           5
        10          8
        11          6
        13          1
        14          4
        15          1
        2           7
        3          26
        4          24
        5          27
        5 7         2
        5 9         1
        6          19
        7          22
        8          23
        8 10        1
        9           6
        A           2
        B           3
        C           2
        D           9
2.0     10         15
        11         14
        12         16
        13         12
        14         23
        15          1
        16          3
        4           7
        7           1
        9          16
        B           1
        D           2
3.0     10          6
        11          5
        12          2
        13         26
        13 15       2
        13 15 B     1
        14          5
        15         35
        15 16       1
        16         20
        2           6
        6           1
        9           3
        A           5
        B           4
        C          35
        C D         2
        D           8
dtype: int64
```

```
boat
1           5
10         29
11         25
12         18
13         39
13 15       2
13 15 B     1
14         32
15         37
15 16       1
16         23
2          13
3          26
4          31
5          27
5 7         2
5 9         1
6          20
7          23
8          23
8 10        1
9          25
A           7
B           8
C          37
C D         2
D          19
dtype: int64

Średnia ilość osób na łódź: 17.666666666666668

Text(0.5, 1.0, 'Ilość pasażerów na poszczególnych łodziach (wartość wg klas).')
```




```
Ilość łodzi: 27
Szacowania ilość osób na łodzi: 945 - założenie 35 osób na łódź. Ilość uratowanych: 500. R
óżnica: 445
```

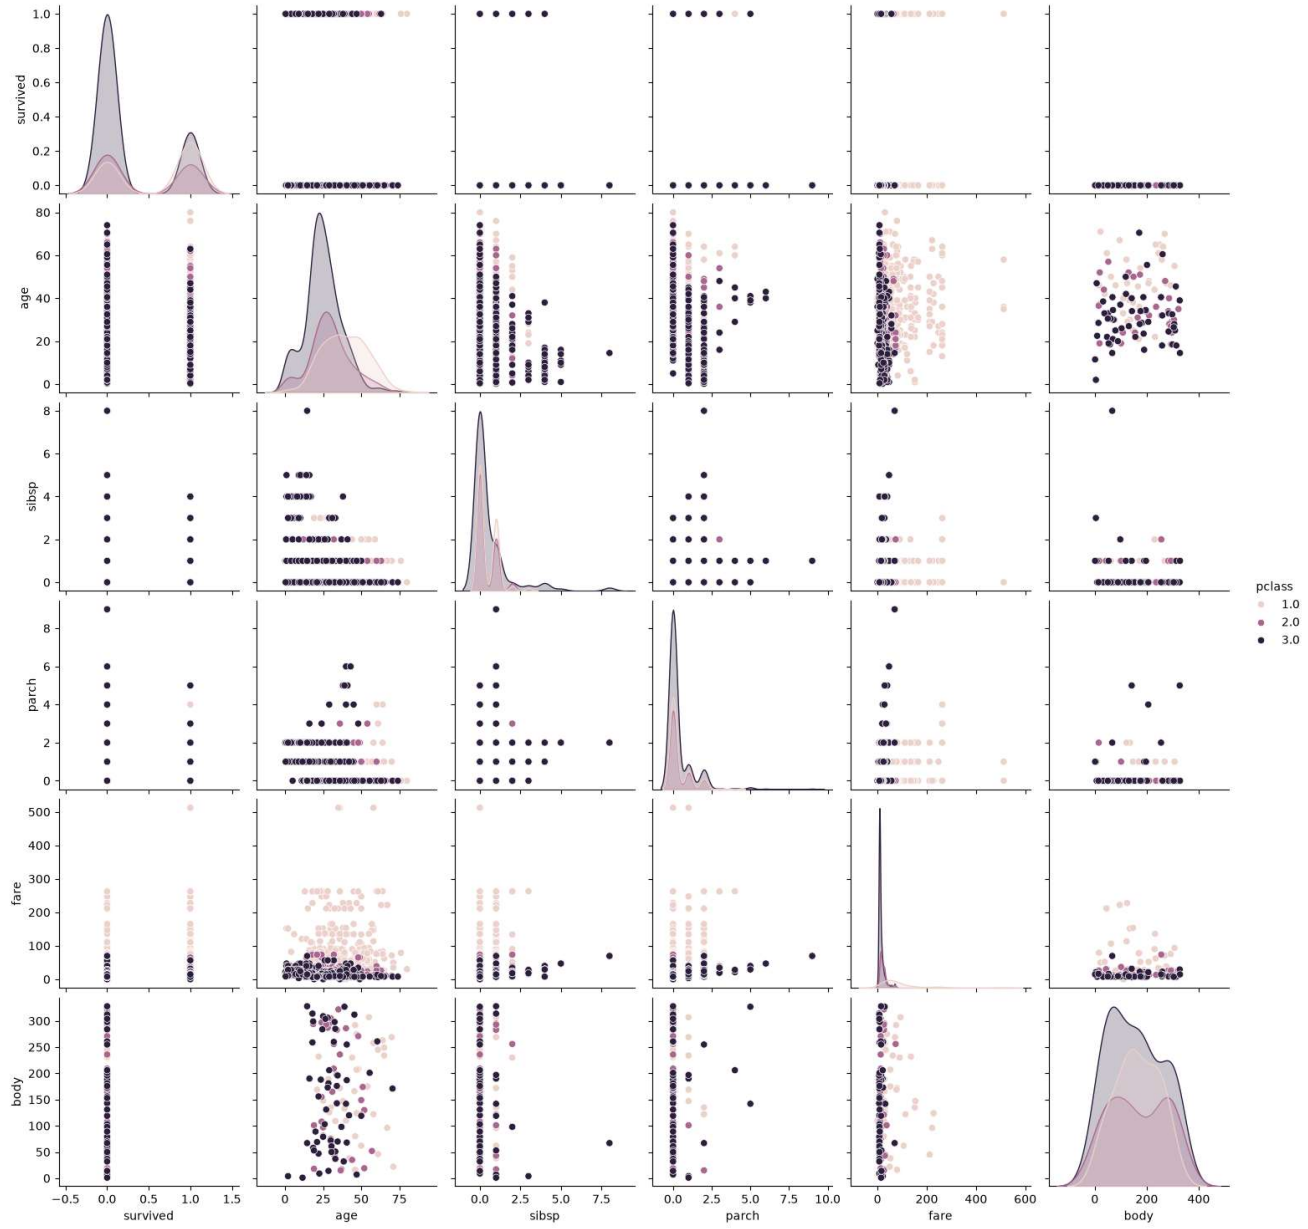
- Z wykresu można wywnioskować że Klasa 3 miała najmniejszy dostęp do ilości łodzi a klasa 1 największy dostęp (widoczny przywilej wchodzenia na łodzie). Pasażerowie z klas 1 i 2 jako jedyni pływali z małą ilością osób na łodzi. Tylko Kilka łodzi było wypełnione po brzegi. Teoretycznie można było spokonie zmieścić dużo więcej osób i uratować w ten sposób przynajmniej 30-40% więcej ludzi.

	pclass	survived	age	sibsp	parch	fare	body
pclass	1.000000	-0.312469	-0.408106	0.060832	0.018322	-0.558694	-0.034642
survived	-0.312469	1.000000	-0.055513	-0.027825	0.082660	0.244426	NaN
age	-0.408106	-0.055513	1.000000	-0.243699	-0.150917	0.177484	0.058809
sibsp	0.060832	-0.027825	-0.243699	1.000000	0.373587	0.160357	-0.099961
parch	0.018322	0.082660	-0.150917	0.373587	1.000000	0.221641	0.051099
fare	-0.558694	0.244426	0.177484	0.160357	0.221641	1.000000	-0.046659
body	-0.034642	NaN	0.058809	-0.099961	0.051099	-0.046659	1.000000

- Macierz korelacji

- zauważone zależności:

- `'pclass' - 'fare'` (klasa - Cenabiletu): Czym lepsza klasa, cena jest wyższa. Rozbieżność ceny spora w 1 klasie (widoczne są wartości mocno odstające)
- `'pclass' - 'age'`
  - są to zależności średnio mocne

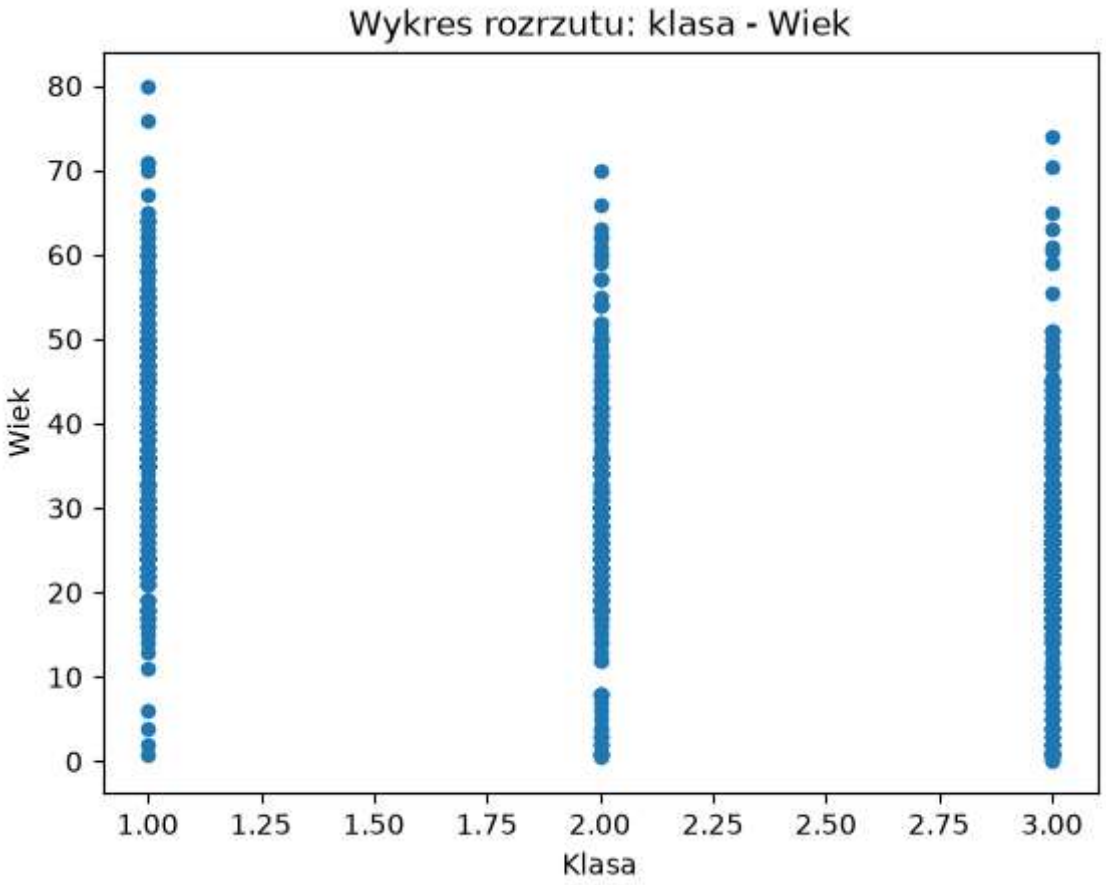


- Scatter plot

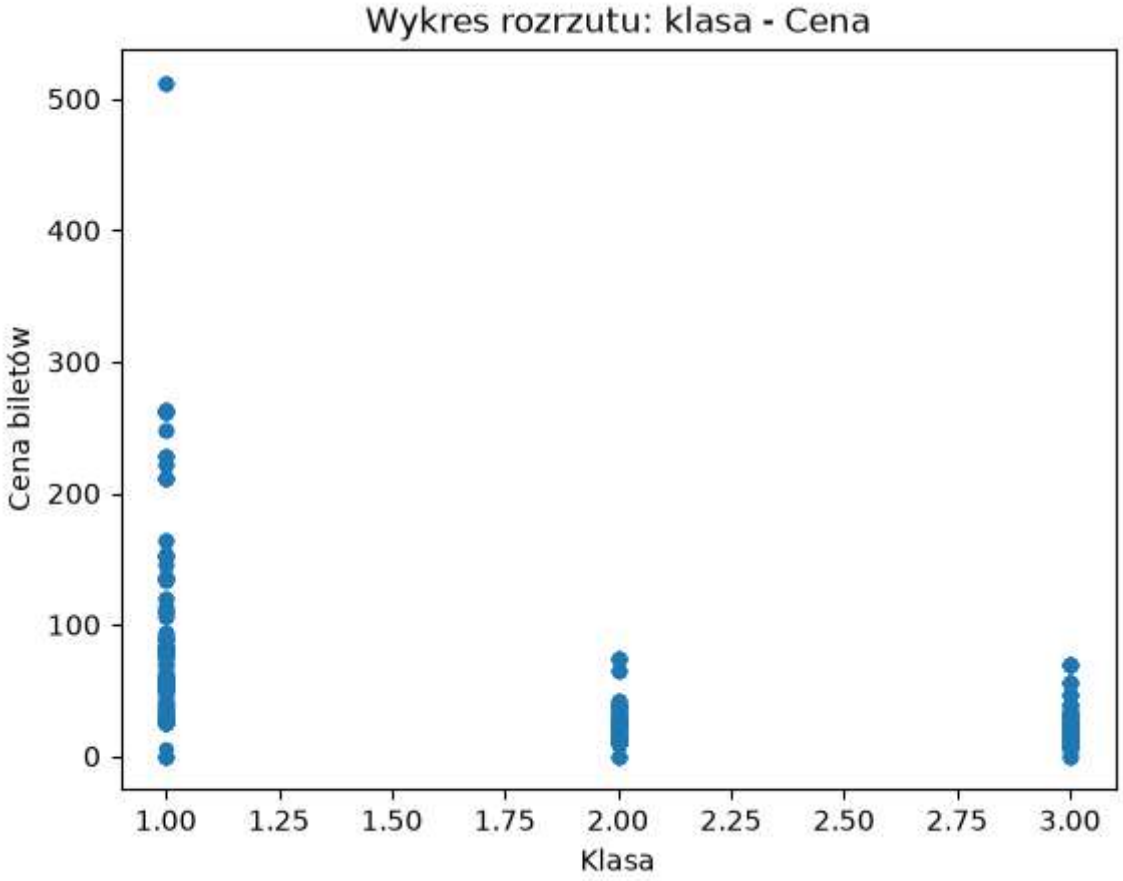
Z Scatter plot można odczytać, że zależność:

- śmierci a wiek nie miała większej zależności. Niezależnie od wieku każdego mogło sięgnąć choć widać większy rozkład starszych osób z 1 klasy. 1 Klasa również miała największy odsetek ludzi starszych 50% wiek: 60+.
-

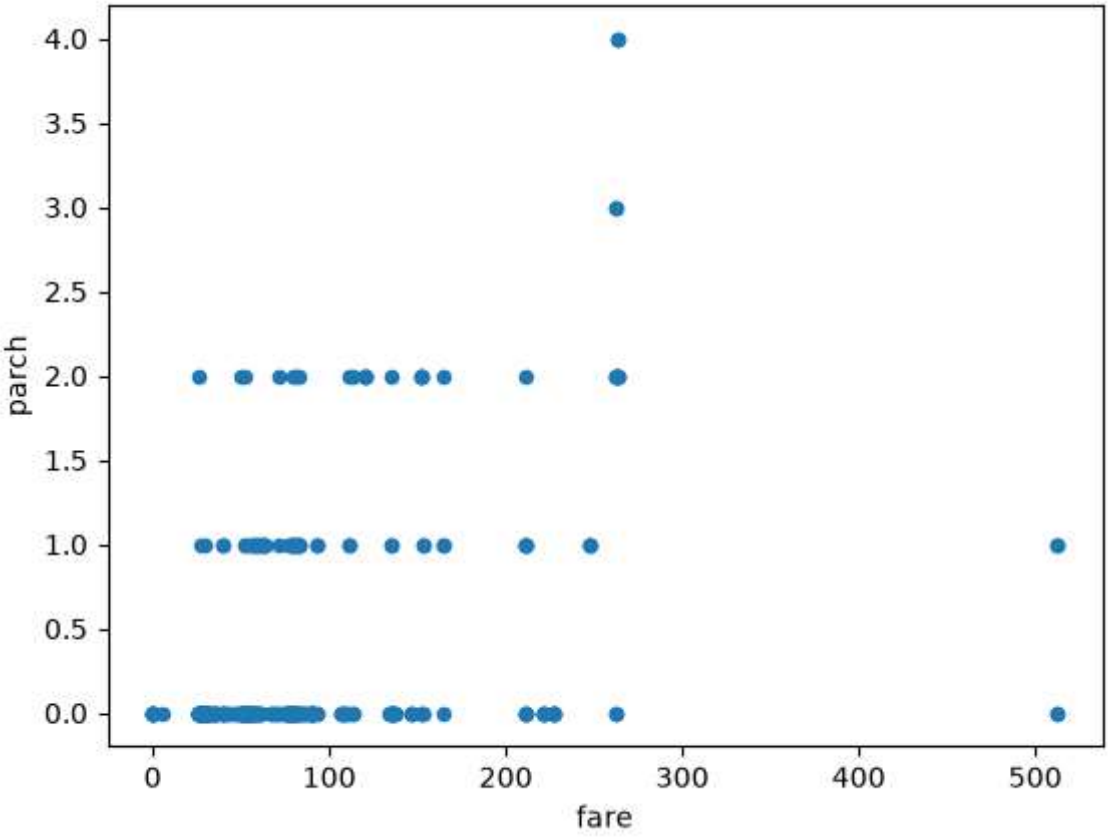
```
Text(0.5, 1.0, 'Wykres rozrzutu: klasa - Wiek')
```

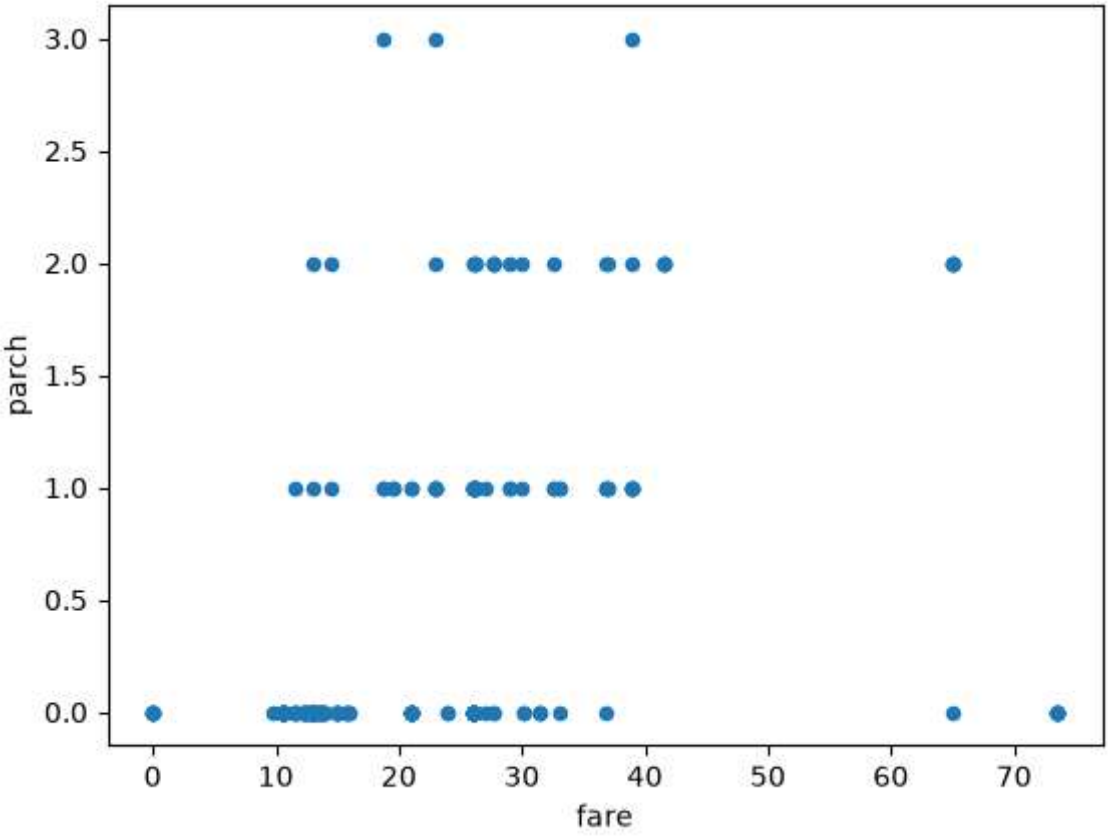


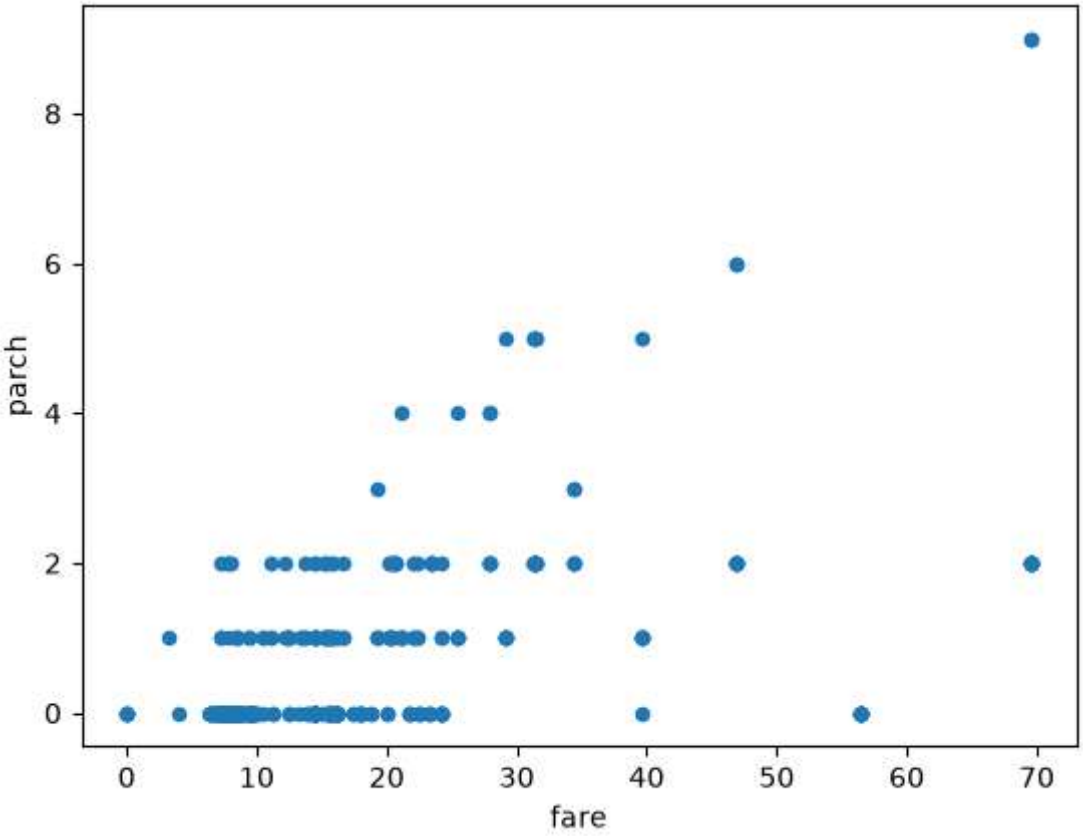

```
Text(0.5, 1.0, 'Wykres rozrzutu: klasa - Cena')
```

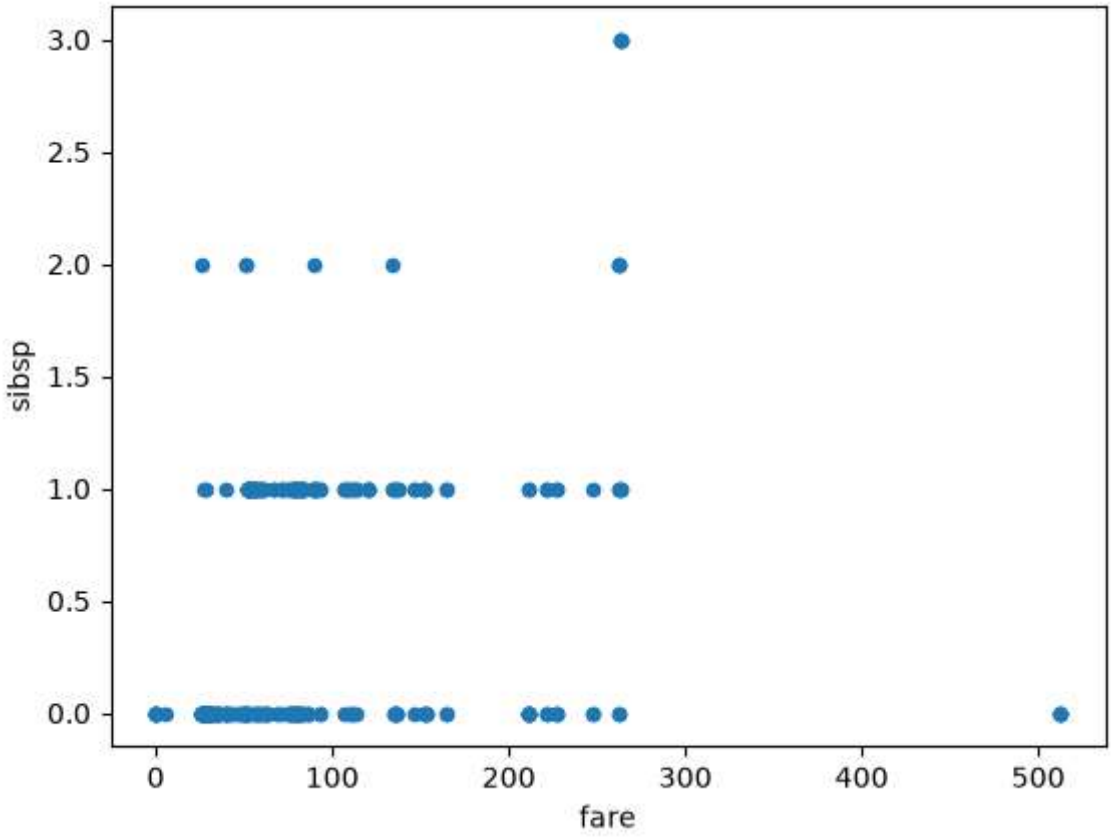


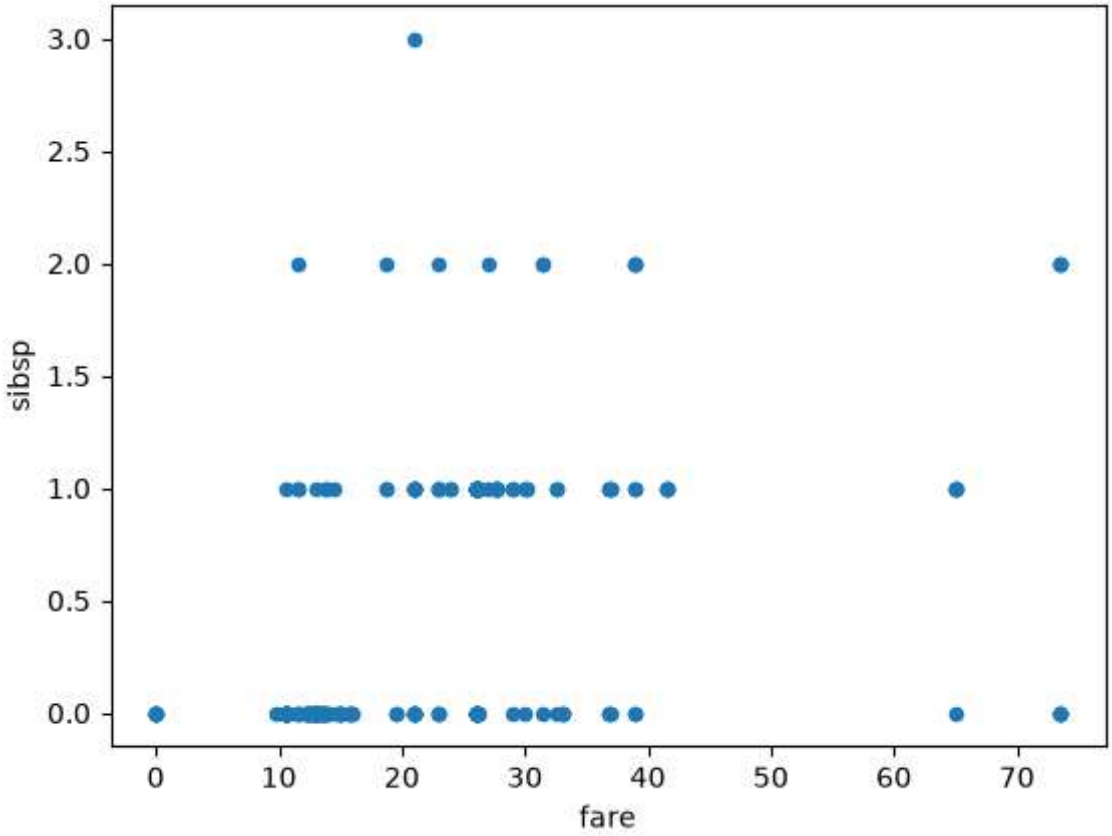
pclass		survived	age	sibsp	parch	fare	body
1.0	**survived**	1.000000	-0.212332	0.154052	0.106502	0.166919	NaN
	age	-0.212332	1.000000	-0.040627	-0.140684	-0.107853	0.154015
	sibsp	0.154052	-0.040627	1.000000	0.281376	0.264400	0.023822
	parch	0.106502	-0.140684	0.281376	1.000000	0.403793	0.110792
	fare	0.166919	-0.107853	0.264400	0.403793	1.000000	-0.198124
	body	NaN	0.154015	0.023822	0.110792	-0.198124	1.000000
2.0	**survived**	1.000000	-0.303042	0.138337	0.402689	0.116859	NaN
	age	-0.303042	1.000000	-0.182158	-0.253386	-0.185523	-0.198017
	sibsp	0.138337	-0.182158	1.000000	0.282419	0.464133	0.159521
	parch	0.402689	-0.253386	0.282419	1.000000	0.403269	-0.291613
	fare	0.116859	-0.185523	0.464133	0.403269	1.000000	0.161455
	body	NaN	-0.198017	0.159521	-0.291613	0.161455	1.000000
3.0	**survived**	1.000000	-0.162933	-0.079406	-0.004953	-0.019688	NaN
	age	-0.162933	1.000000	-0.383911	-0.135668	-0.235742	0.129697
	sibsp	-0.079406	-0.383911	1.000000	0.406932	0.740661	-0.201609
	parch	-0.004953	-0.135668	0.406932	1.000000	0.621111	0.124124
	fare	-0.019688	-0.235742	0.740661	0.621111	1.000000	-0.049379
	body	NaN	0.129697	-0.201609	0.124124	-0.049379	1.000000

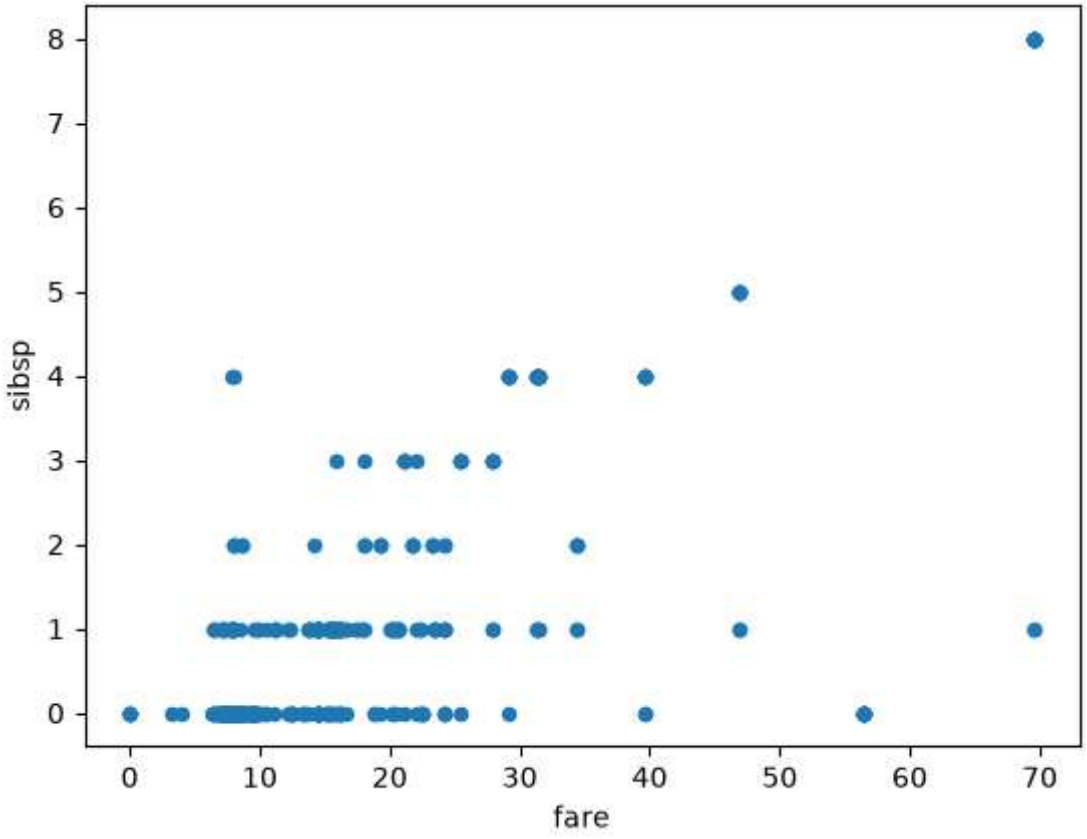

4.0
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
parch
0
100
200
300
400
500
fare


3.0
2.5
2.0
1.5
1.0
0.5
0.0
parch
0
10
20
30
40
50
60
70
fare


parch
fare
0
2
4
6
8
0
10
20
30
40
50
60
70


sibsp
fare
0.0
0.5
1.0
1.5
2.0
2.5
3.0
0
100
200
300
400
500



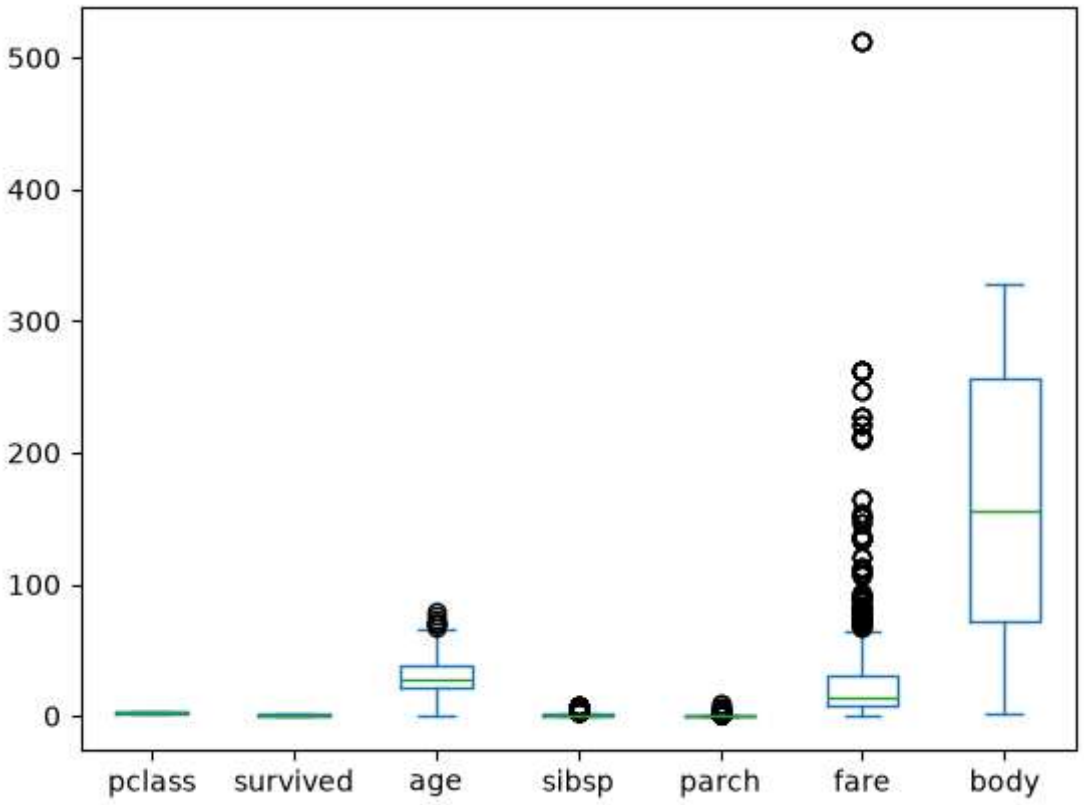


- Macierz korrelacji a rozgrupowanie na klasy

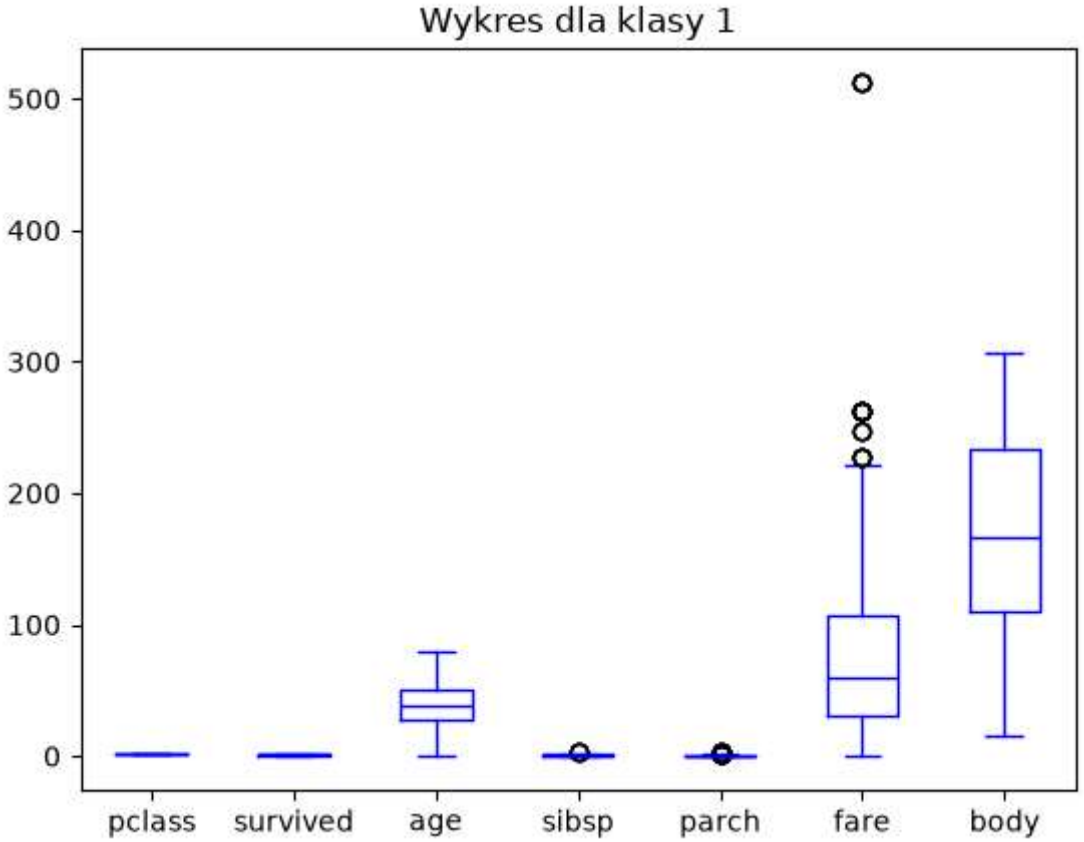
Klasa 1 i Klasa 2. nie mają znaczących widocznych zależności lecz w klasie 3 widać już widoczną zależność między 'sibsp' (Rodziny) oraz 'fare' (Cena biletów).

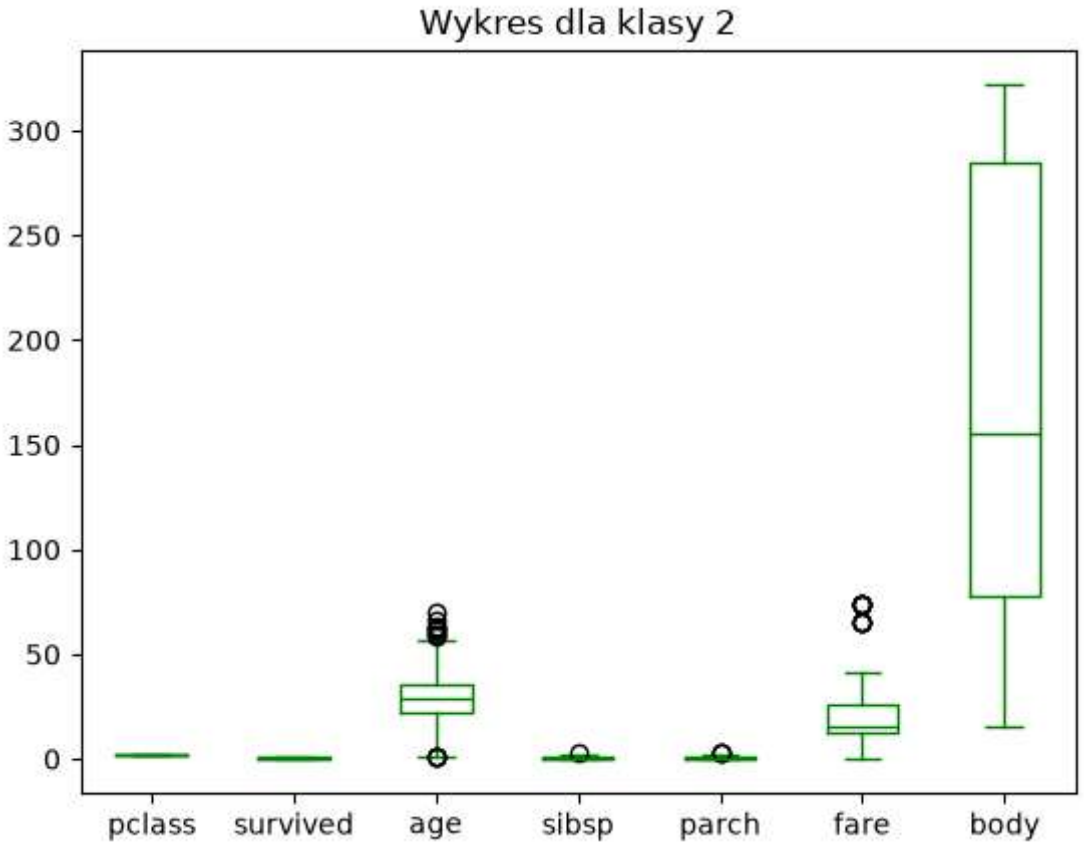
- Wartości odstające

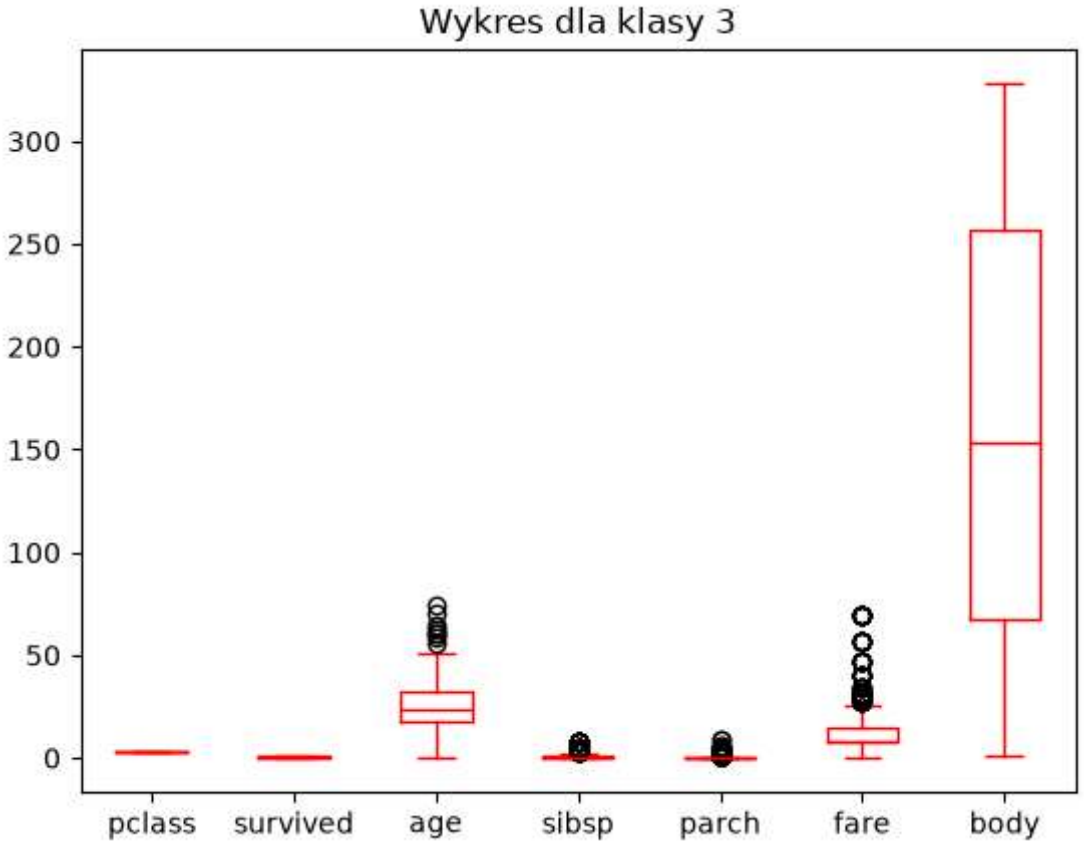
<Axes: >



Klasa: 1 - kolor: blue
Klasa: 2 - kolor: green
Klasa: 3 - kolor: red

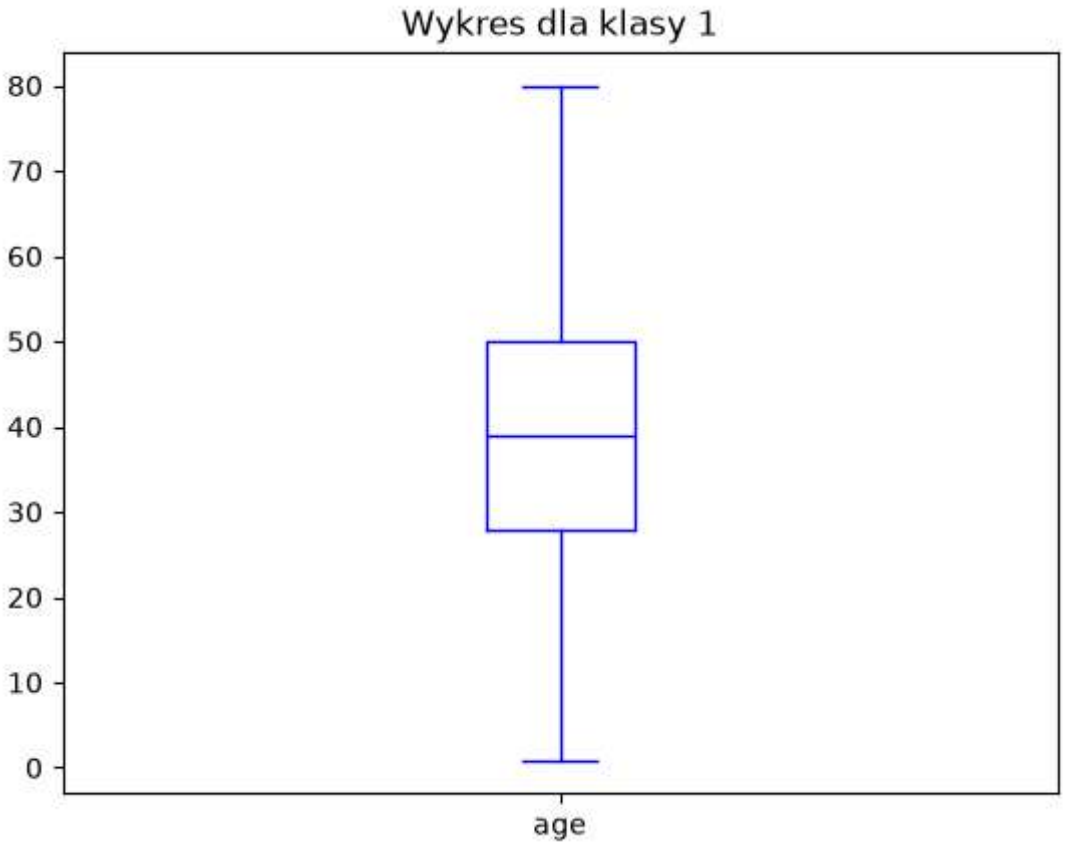


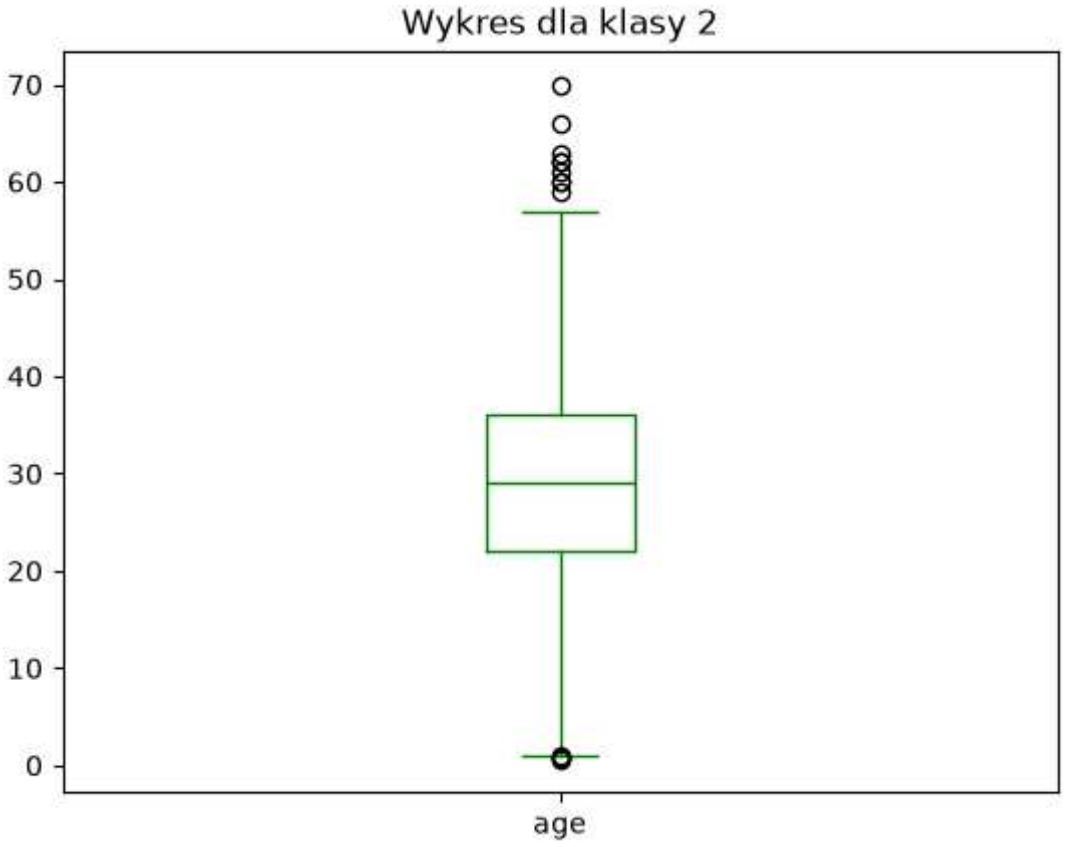


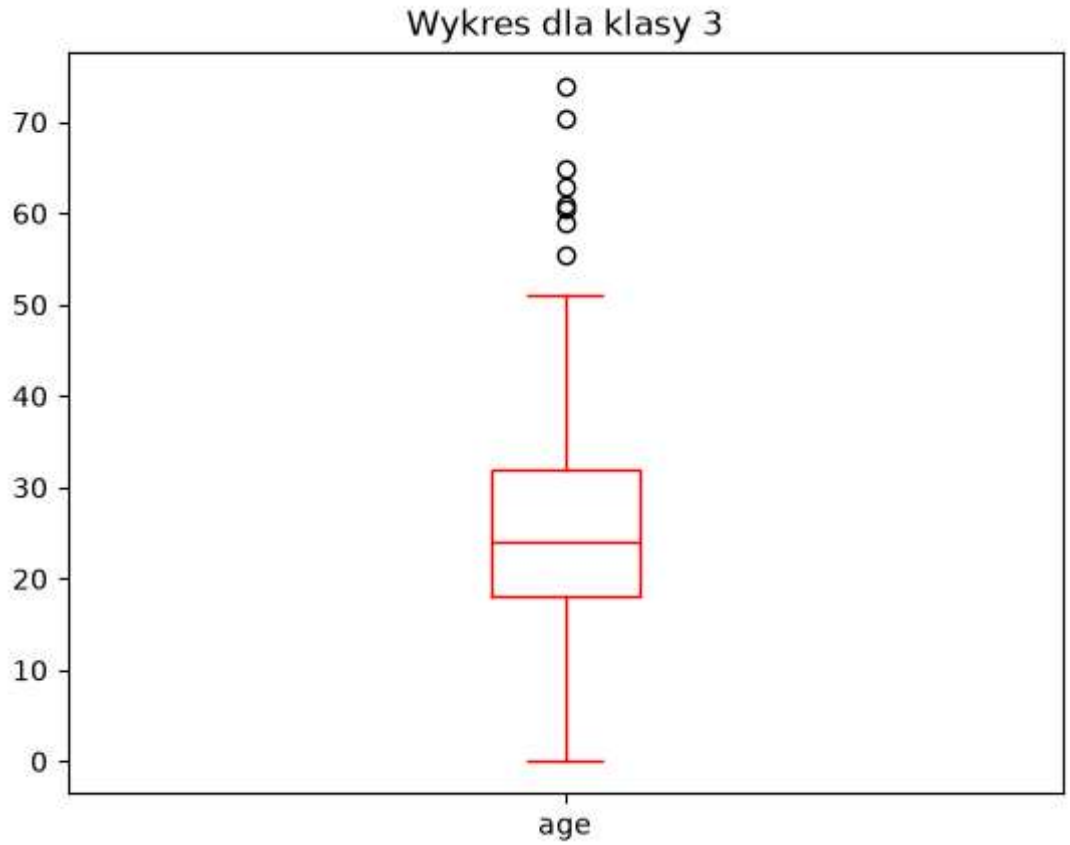


Wartości odstające występują w wiek, rodzeństwo, rodzice, cena biletów

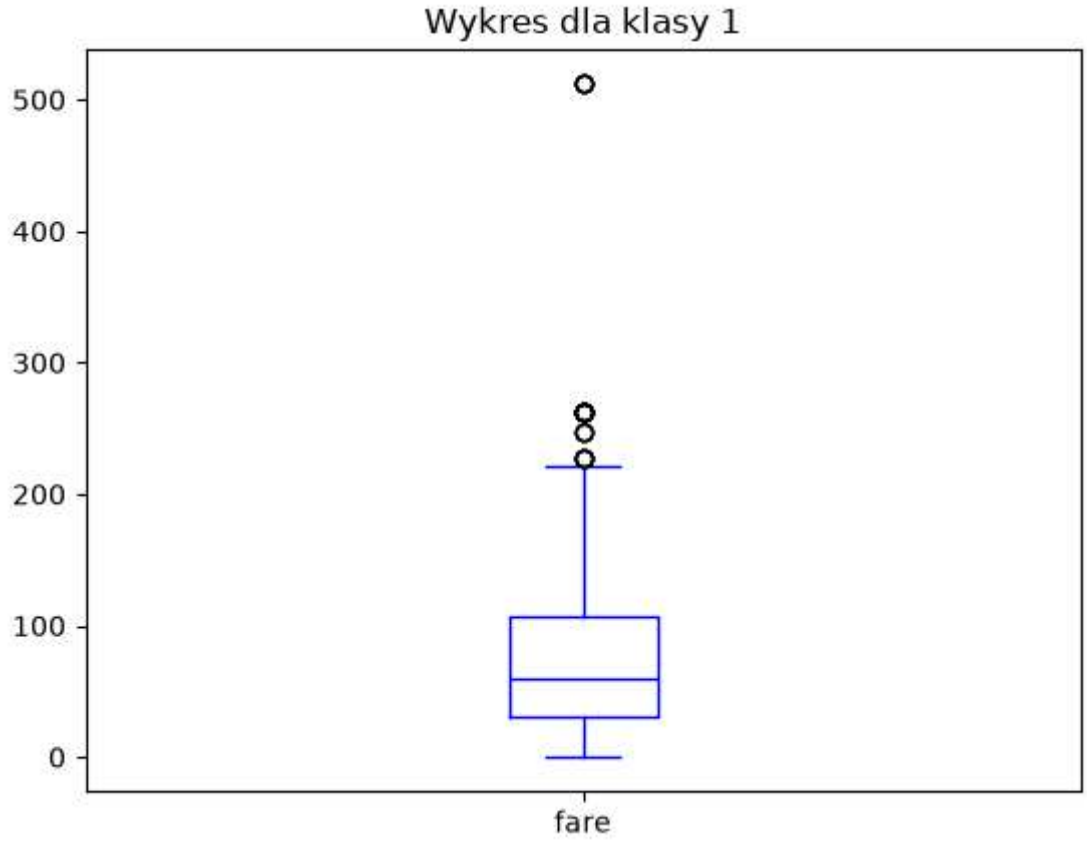
```
Klasa: 1 - kolor: blue
Klasa: 2 - kolor: green
Klasa: 3 - kolor: red
```

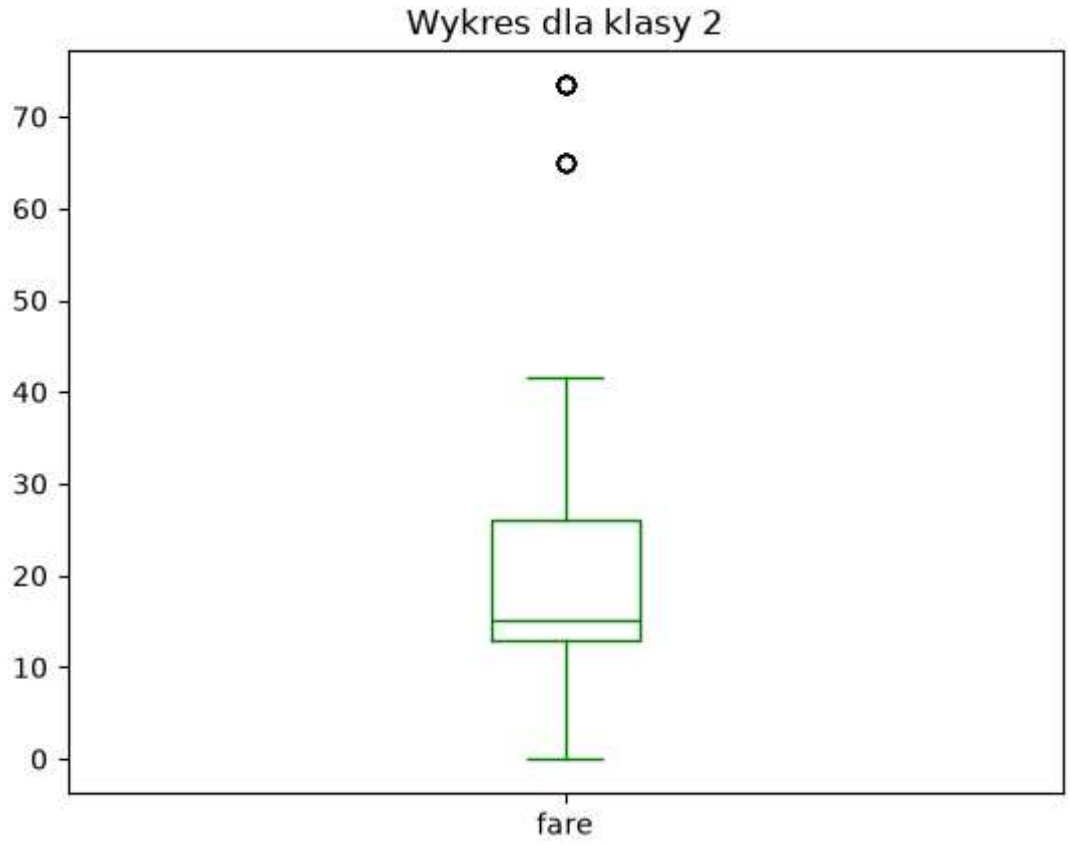

Wykres dla klasy 1
80
70
60
50
40
30
20
10
0
age

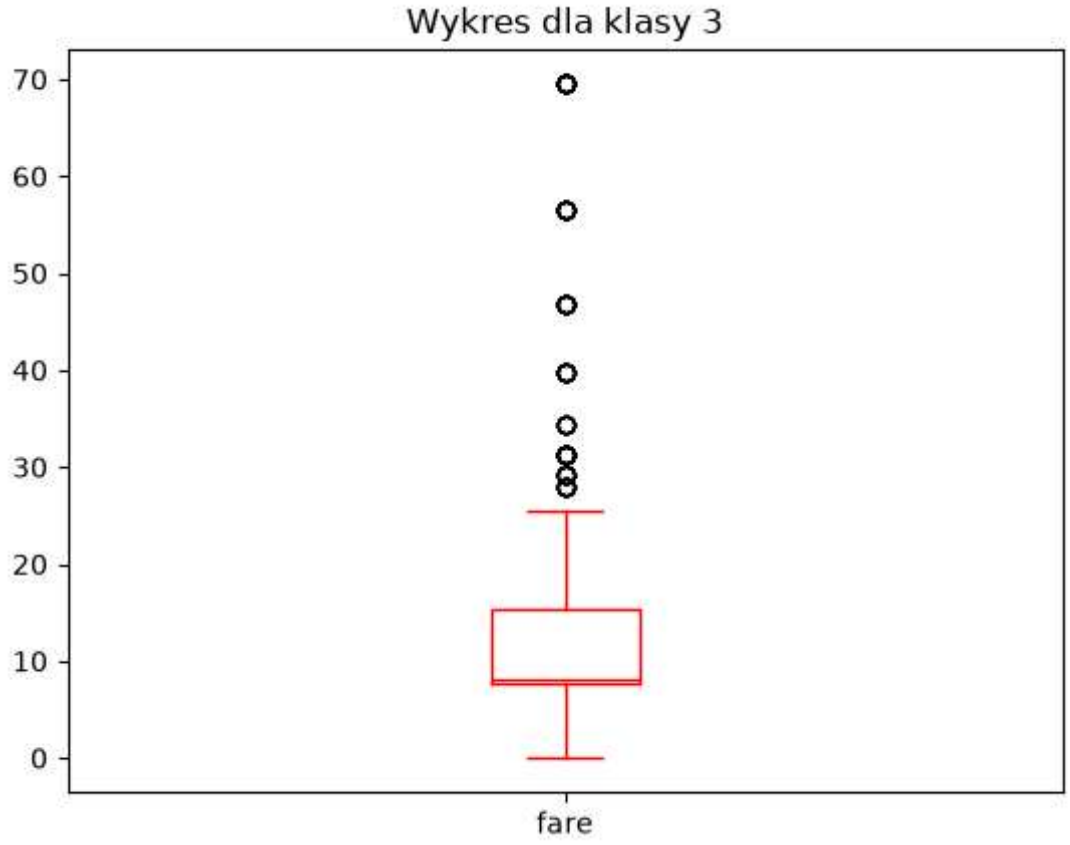

Wykres dla klasy 2
70
60
50
40
30
20
10
0
age



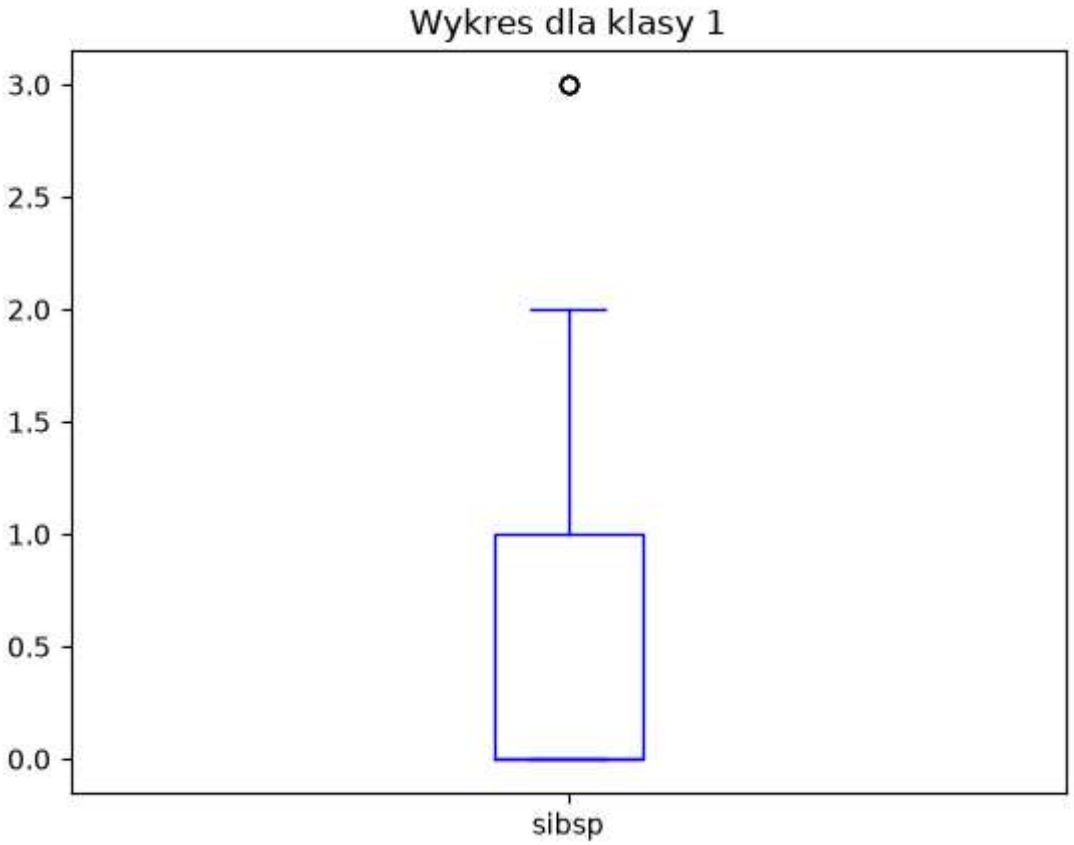

```
Klasa: 1 - kolor: blue
Klasa: 2 - kolor: green
Klasa: 3 - kolor: red
```

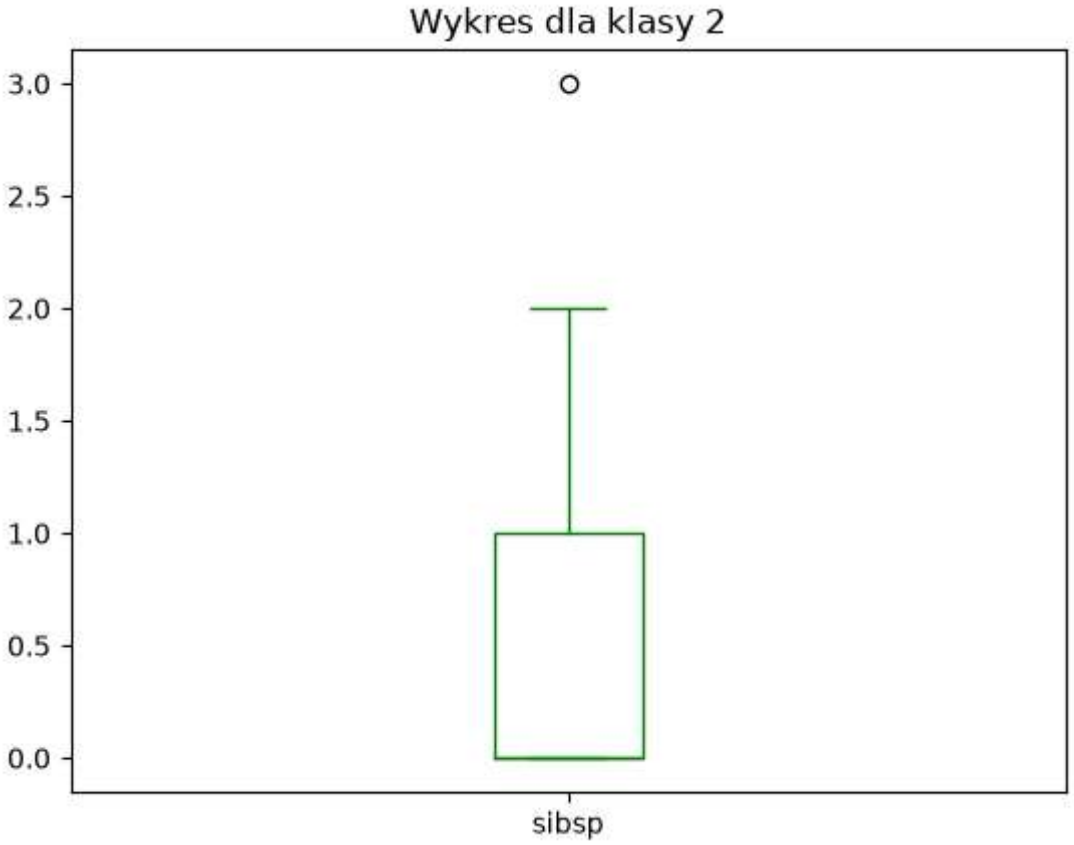


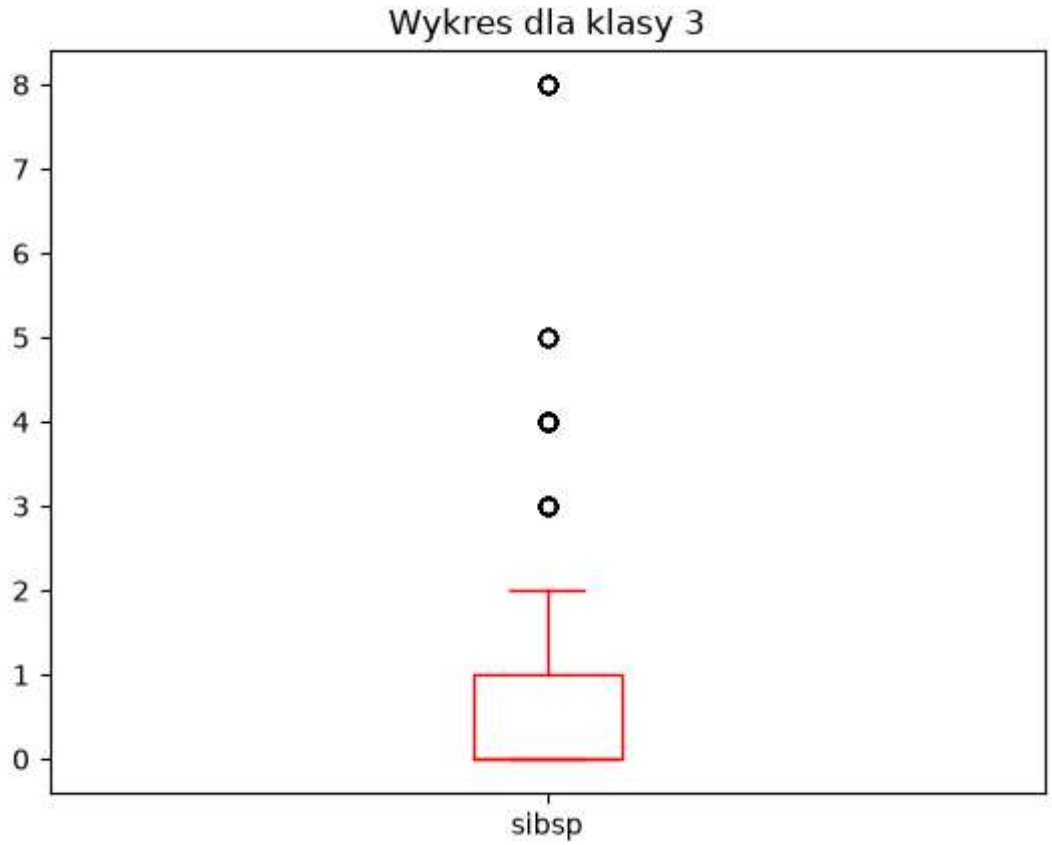




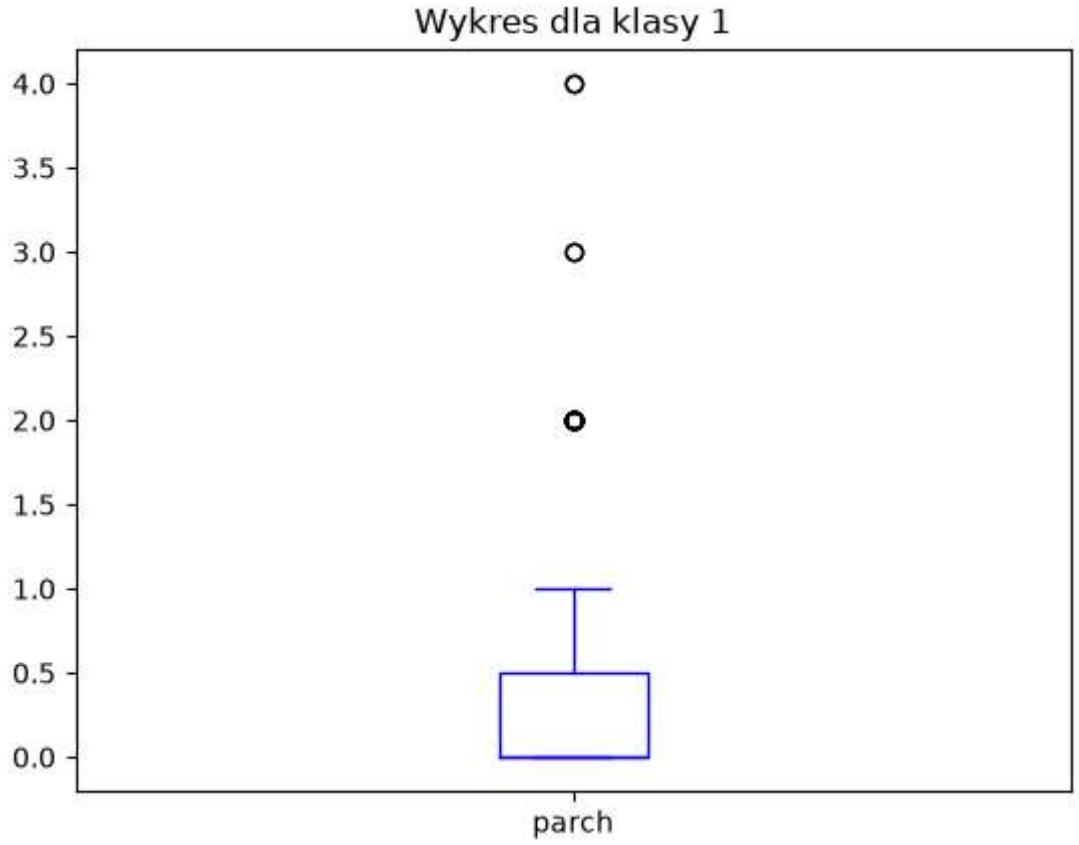

```
Klasa: 1 - kolor: blue
Klasa: 2 - kolor: green
Klasa: 3 - kolor: red
```

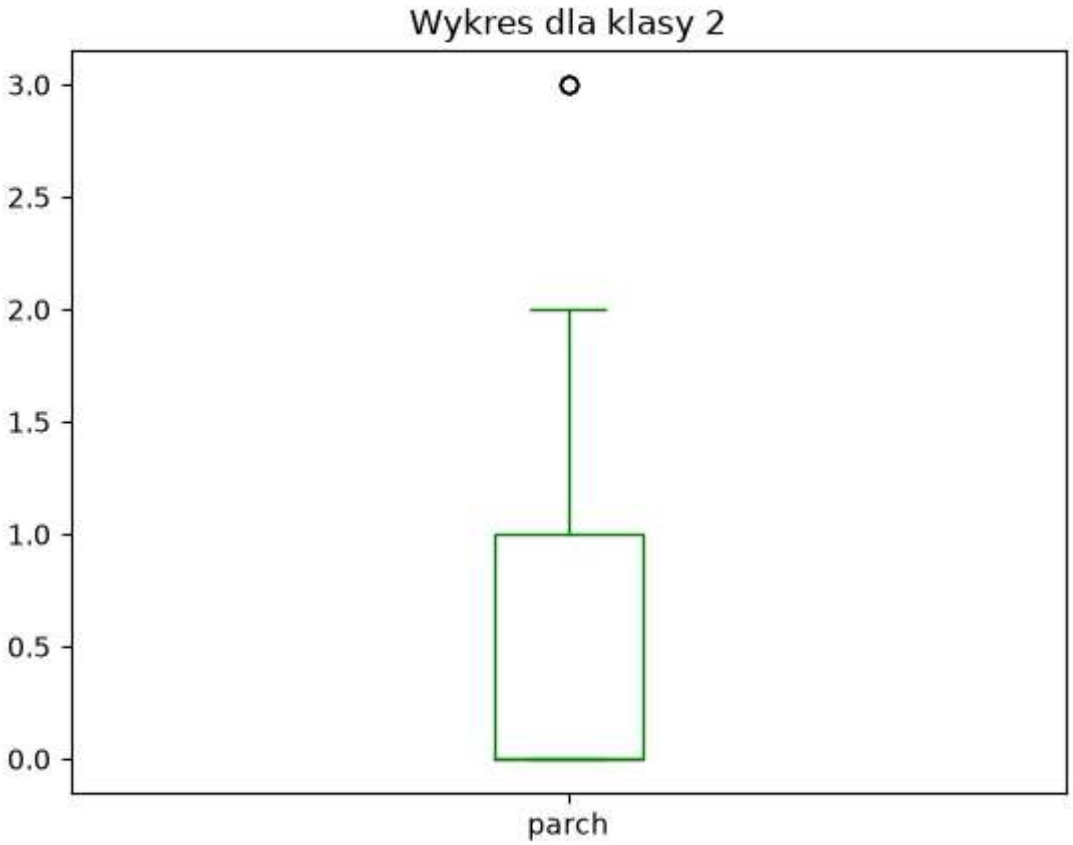

Wykres dla klasy 1
3.0
2.5
2.0
1.5
1.0
0.5
0.0
sibsp

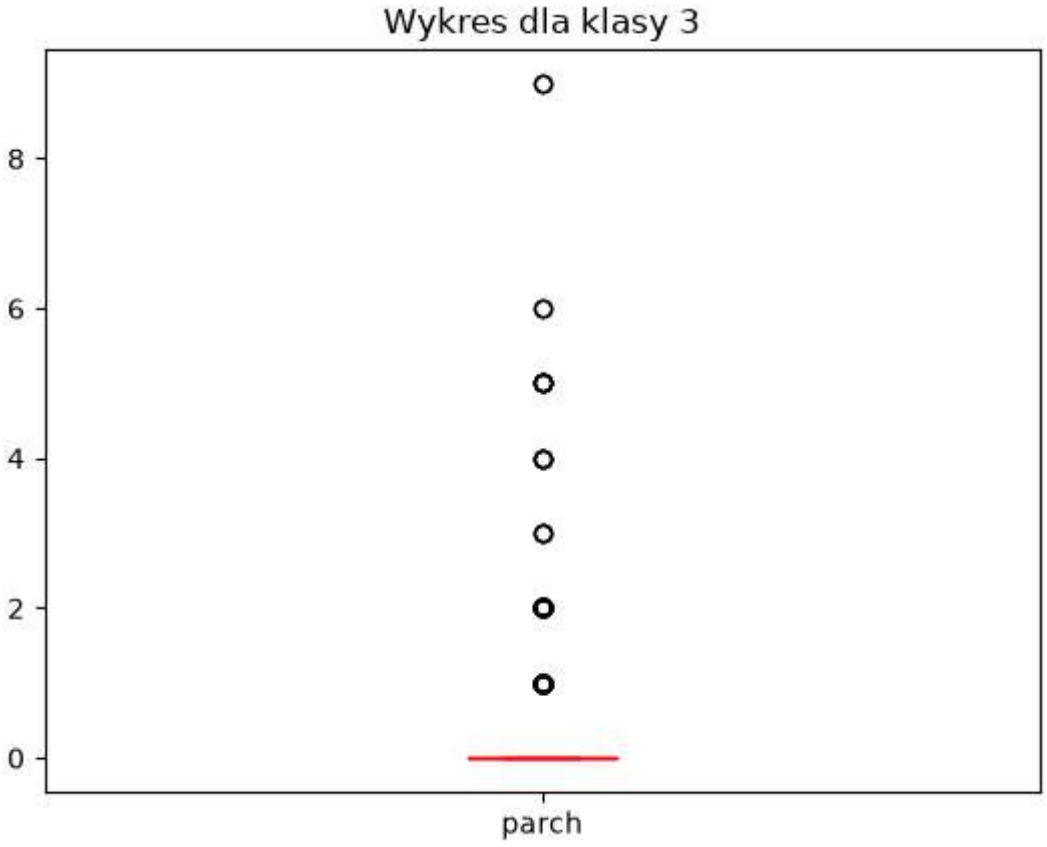

Wykres dla klasy 2
3.0
2.5
2.0
1.5
1.0
0.5
0.0
sibsp




```
Klasa: 1 - kolor: blue
Klasa: 2 - kolor: green
Klasa: 3 - kolor: red
```







- Wartości odstające - Wnioski

- Odchylenia w `cenach` widoczne najbardziej w 1 klasie. Najbardziej zbliżone ceny były w klasie 3.
- Odchylenia w `Wieku` widocznie w 2 i 3 klasie gdzie Barplot potwierdza wcześniejsze spostrzeżenia że wiek w 3 klasie jest bardziej skupiony miedzy 20-30 rokiem życia. W innych jest

adekwatnie rozciągnięty

- Odchylenia w `Rodzeństwie / małżonków`: wykresy w każdej klasie wyglądają identycznie. Różnią się jedynie ilością wartości odstających:
  - po jednym przypadku w klasie 1 i 2.
  - 4 przypadki w klasie 3.
- Odchylenia w `Rodzice / dzieci`: wykresy w każdej klasie się różnią. Najwięcej odchyleń w 3 klasie i najczęściej bez rodziców / dzieci. Może to wynikać z dużej puli ilości osób z tej klasy.

6. Wnioski

1. Brak pełnych danych
   A. Na tytaniku było ponad 2200 osób
   B. zmarło ponad 1500
   C. Dane posiadane o 1309 (+1 pusty zbiór) pasażerach więc dane są niepełne.
   D. W celu dalszej analizy założy się, że brakujące informacje nie wpłyną na wyniki
2. Ceny biletów potrafiły się wachać z czego największe wachania ceny były w klasie 1.
3. Wiek podróżnych:
   A. W Klasie 1 najczęściej podróżowały osoby w wieku 20-50 lat.
   B. W Klasie 2 najczęściej podróżowały osoby w wieku 20-50 lat lecz widać prawie 2 krotnie więcej osób w innych ramach w wieku około 30 lat.
   C. W Klasie 3 najczęściej podróżowały osoby w wieku 0-50 lat lecz widać bardzo dużo osób przeważających w wieku 16-32 lata oraz największy udział dzieci
4. Ile osób przeżyło w danej klasie:
   A. Klasa 1: 200
   B. Klasa 2: 119
   C. Klasa 3: 181
5. Mimo, że na statku przeważali ilościowo mężczyźni to przeżyło znacznie więcej kobiet, miały więc większe szanse na przeżycie prawdopodobnie ze względu na pierwszeństwo na szalupy ratunowe. Klasa biletu miała również duże znaczenie na szanse przeżycia.
   A. 1.0: kobiety 96.53 % , mężczyźni 34.08 %
   B. 2.0: kobiety 88.68 % , mężczyźni 14.62 %
   C. 3.0: kobiety 49.07 % , mężczyźni 15.21 %
6. Miasto wsiadania na pokład a przeżycie: mimo że najwięcej osób co przeżyło startowało z miasta **Southampton** (61% na szalupach) to w porównaniu z ilością osób na pokładzie z danego miasta wynika, że proporcjonalnie więcej osób przeżyło z miasta **Cherbourg** (31% na szalupach) gdzie już miało **55%** frekwencję przeżycia. Z tych wniosków ciężko mi jest określić czy jakiś większy / znaczący wpływ miało miejsce wsiadania na pokład.
   A. Cherbourg: 55.56 %
   B. Queenstown: 35.77 %
   C. Southampton: 33.26 %
7. Dzieci (0-17 lat) też miały duży odsetek przeżycia lecz tylko w klasach 1 i 2 (ponad 86%). Dzieci z 3 klasy widać miały mniejsze szanse na przeżycie niż dorośli z 1 klasy.
   A. Klasa: 1.0: **86.666667 %**
   B. Klasa: 2.0: **87.878788 %**
   C. Klasa: 3.0: **36.792453 %**

8. śmierć a wiek nie miał większej zależności w klasie 1. Niezależnie od wieku każdego mogło sięgnąć choć widać większy rozkład starszych osób. W pozostałych dwóch klasach juz widać że młodsze osoby miały większą przeżywalność niż osoby starsze. Czyżby w tych klasach częściej przepuszczali młode osoby na szalupy?

Poniżej według mnie najważniejsze współczynniki przeżycia numerując kolejnością ważności:

1. **Płeć - Kobiety**
2. **Klasa biletu / przynależnosć społeczeństwa**
3. **Młody Wiek w szczególności w klasie 2 i 3**